Analyse Exploratoire des Données (EDA) - Banque Mondiale

1. Imports

Nous configurons l'environnement et listons les sources de données brutes. Pour visualiser les données, nous définissons d'abord le chemin d'accès (**path**) où sont stockés les fichiers CSV. Nous récupérons ensuite la liste de ces fichiers dans une variable `all_files` en utilisant un pattern de recherche (**globbing**) avec l'extension `*.csv`.

2. Chargement des données

Boucle d'itération et rendu des données

Cette étape permet de valider l'intégrité des fichiers CSV et d'obtenir un premier aperçu visuel des structures.

- **Identification** : Nous affichons le nom du fichier pour confirmer la lecture.
- **Chargement** : Le contenu est chargé dans un **DataFrame**.
- **Rendu** : Nous utilisons `display(df.head())` pour générer un rendu visuel des 5 premières entrées.

Gestion des exceptions (Error Handling)

En cas d'erreur lors de la lecture ou de l'affichage, un bloc `try...except` permet de capturer l'exception. Le script affiche alors le nom du fichier problématique ainsi que le message d'erreur associé pour faciliter le débogage.

> **Note technique** :
>
> - **os** : Ce module fournit des fonctions pour interagir avec le système d'exploitation. Nous l'utilisons ici pour manipuler les chemins de fichiers (paths) de manière agnostique
> - **glob** : Cette bibliothèque est utilisée pour la recherche de fichiers via des patterns. Le globbing permet de lister tous les fichiers correspondant à une extension spécifique (ex: *.csv).
> - **pd.read_csv()** : C'est la fonction fondamentale de Pandas pour transformer un fichier CSV en un objet DataFrame (tableau structuré en lignes et colonnes).

> - **display()** : Une fonction spécifique à l'environnement IPython (Jupyter/DataSpell) qui permet un rendu HTML élégant des objets, plus lisible que le simple print().
> - **head(n)** : Cette méthode retourne les n premières lignes d'un DataFrame (par défaut 5).
> - **Gestion des exceptions : try... expect** : Ce bloc permet de tester un bloc de code (try). Si une erreur survient (fichier corrompu, chemin erroné), le programme ne plante pas brutalement mais exécute le bloc except, nous permettant d'afficher un message d'erreur personnalisé.

```
import numpy as np
import pandas as pd
import glob
import os
from IPython.display import Markdown
import matplotlib.pyplot as plt
import seaborn as sns
from IPython.core.interactiveshell import InteractiveShell
InteractiveShell.ast_node_interactivity = "all"

path = 'data'
all_files = glob.glob(os.path.join(path , "*.csv"))
dataframes = []

for file in all_files:
    try:
        file_name = os.path.basename(file)
        df = pd.read_csv(file)
        dataframes.append({"name": file_name, "data": df})
    except Exception as e:
        print(f"Erreur sur {file}: {e}")
```

```
display(Markdown(f"## Analyse du fichier : {dataframes[0]['name']}"))
```

Analyse du fichier : EdStatsCountry.csv

```
print(f"--- Fichier : {dataframes[0]['name']} ---")
display(dataframes[0]['data'].head())
```

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Income Group
0	ABW	Aruba	Aruba	Aruba	AW	Aruban florin	SNA data for 2000-2011 are updated from offici...	Latin America & Caribbean	High income: nonOECD
1	AFG	Afghanistan	Afghanistan	Islamic State of Afghanistan	AF	Afghan afghani	Fiscal year end: March 20; reporting period fo...	South Asia	Low income
2	AGO	Angola	Angola	People's Republic of Angola	AO	Angolan kwanza	April 2013 database update: Based on IMF data,...	Sub-Saharan Africa	Upper middle income
3	ALB	Albania	Albania	Republic of Albania	AL	Albanian lek	NaN	Europe & Central Asia	Upper middle income
4	AND	Andorra	Andorra	Principality of Andorra	AD	Euro	NaN	Europe & Central Asia	High income: nonOECD

5 rows × 32 columns

```
display(Markdown(f"## Analyse du fichier : {dataframes[1]['name']}"))
```

Analyse du fichier : EdStatsCountry-Series.csv

```
print(f"--- Fichier : {dataframes[1]['name']} ---")
display(dataframes[1]['data'].head())
```

	CountryCode	SeriesCode	DESCRIPTION	Unnamed: 3
0	ABW	SP.POP.TOTL	Data sources : United Nations World Population...	NaN
1	ABW	SP.POP.GROW	Data sources: United Nations World Population ...	NaN
2	AFG	SP.POP.GROW	Data sources: United Nations World Population ...	NaN
3	AFG	NY.GDP.PCAP.PP.CD	Estimates are based on regression.	NaN
4	AFG	SP.POP.TOTL	Data sources : United Nations World Population...	NaN

```
display(Markdown(f"## Analyse du fichier : {dataframes[2]['name']}"))
```

Analyse du fichier : EdStatsData.csv

```
print(f"--- Fichier : {dataframes[2]['name']} ---")
display(dataframes[2]['data'].head())
```

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	
1	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	
2	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	
3	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	NaN	
4	Arab World	ARB	Adjusted net enrolment rate, primary, both sex...	SE.PRM.TENR	54.822121	54.894138	56.209438	57.267109	57.

5 rows × 70 columns

```
display(Markdown(f"## Analyse du fichier : {dataframes[3]['name']}"))
```

Analyse du fichier : EdStatsFootNote.csv

```
print(f"--- Fichier : {dataframes[3]['name']} ---")
display(dataframes[3]['data'].head())
```

	CountryCode	SeriesCode	Year	DESCRIPTION	Unnamed: 4
0	ABW	SE.PRE.ENRL.FE	YR2001	Country estimation.	NaN
1	ABW	SE.TER.TCHR.FE	YR2005	Country estimation.	NaN
2	ABW	SE.PRE.TCHR.FE	YR2000	Country estimation.	NaN
3	ABW	SE.SEC.ENRL.GC	YR2004	Country estimation.	NaN
4	ABW	SE.PRE.TCHR	YR2006	Country estimation.	NaN

```
display(Markdown(f"## Analyse du fichier : {dataframes[4]['name']}"))
```

Analyse du fichier : EdStatsSeries.csv

```
print(f"--- Fichier : {dataframes[4]['name']} ---")
display(dataframes[4]['data'].head())
```

	Series Code	Topic	Indicator Name	Short definition	Long definition	Unit of measure	Periodicity	E Pe
0	BAR.NOED.1519.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15-19 with...	Percentage of female population age 15-19 with...	NaN	NaN	
1	BAR.NOED.1519.ZS	Attainment	Barro-Lee: Percentage of population age 15-19 ...	Percentage of population age 15-19 with no edu...	Percentage of population age 15-19 with no edu...	NaN	NaN	
2	BAR.NOED.15UP.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15+ with n...	Percentage of female population age 15+ with n...	NaN	NaN	
3	BAR.NOED.15UP.ZS	Attainment	Barro-Lee: Percentage of population age 15+ wi...	Percentage of population age 15+ with no educa...	Percentage of population age 15+ with no educa...	NaN	NaN	
4	BAR.NOED.2024.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 20-24 with...	Percentage of female population age 20-24 with...	NaN	NaN	

5 rows × 21 columns

3. Nettoyage et Analyse Exploratoire des Données (EDA)

Cette section automatise le processus de nettoyage et d'analyse descriptive pour l'ensemble des fichiers chargés. L'objectif est de garantir l'intégrité des données et d'optimiser la structure des DataFrames avant l'analyse approfondie.

Méthodologie appliquée par fichier :

1. **Définition de l'unité d'observation (*Row definition*)** :
    - Identification de la granularité technique d'une ligne (ex: une observation unique pays/année/indicateur).
2. **Évaluation de la volumétrie (*Shape*)** :

- Calcul du nombre de lignes (*records*) et de colonnes (*features*) pour quantifier le dataset.

3. **Traitement des Redondances (*Deduplication*)** :
   - Détection et suppression des doublons pour éviter de biaiser les futurs calculs statistiques (moyennes, sommes).
4. **Analyse de la complétude (*Missing Values*)** :
   - Calcul de la proportion de valeurs manquantes (`NaN`) par colonne pour évaluer la fiabilité de chaque variable.
5. **Optimisation du Dataset (*Pruning*)** :
   - Suppression des colonnes jugées inutilisables (ex: colonnes techniques vides ou colonnes ayant plus de 90% de valeurs manquantes).
     - Justification technique :
       - **Significativité statistique** : Une variable renseignée à moins de 10% ne permet pas d'extraire des tendances représentatives et introduit un "bruit" analytique (*statistical noise*) qui fausse les mesures de tendance centrale comme les moyennes et les écart-types.
       - **Pertinence temporelle** : Dans le fichier `EdStatsData.csv`, ce seuil permet d'éliminer les projections à très long terme (ex: 2070-2100) qui sont quasi-intégralement vides, tout en conservant les données historiques réelles indispensables à l'analyse.
       - **Performance (*Memory Management*)** : La suppression de ces colonnes réduit l'empreinte mémoire du DataFrame, ce qui accélère les calculs ultérieurs (calculs vectorisés), une pratique essentielle sur des jeux de données dépassant les 800 000 lignes.
6. **Analyse Descriptive (*Numerical & Categorical Features*)** :
   - **Colonnes Numériques** : Application de `.describe()` pour obtenir les mesures de tendance centrale et de dispersion (Min, Max, Moyenne, Quartiles).
   - **Colonnes Catégorielles** : Calcul des occurrences via `.value_counts()` pour identifier les modalités dominantes et les déséquilibres potentiels.

> **Note technique :** Afin de garantir un rendu visuel stable dans l'IDE et un export PDF professionnel, les résultats catégoriels sont convertis en structures tabulaires (*DataFrames*) avant d'être affichés via la fonction `display()`.

3.1 Définition de l'unité d'observation

EdStatsCountry.csv

- **Définition** : Une ligne représente un pays unique ou une entité géographique (ex: une région comme l'Amérique Latine).

- **Clé primaire** : `CountryCode`
- **Contenu** : Toutes les caractéristiques fixes du pays (monnaie, région, système de recensement, etc...)

EdStatsSeries.csv

- **Définition** : Une ligne représente un indicateur statistique unique (un "Series").
- **Clé primaire** : `SeriesCode`
- **Contenu** : Les définitions, les sources et les méthodologies pour chaque type de donnée mesurée (ex: taux d'inscription scolaire).

EdStatsCountry-Series.csv

- **Définition** : Une ligne représente une relation spécifique entre un pays et un indicateur.
- **Clé composite** : `CountryCode` + `SeriesCode`
- **Contenu** : Il sert de table de liaison. Il précise souvent la source de données spécifique utilisée pour cet indicateur dans ce pays précis (colonne `DESCRIPTION`).

EdStatsFootNote.csv

- **Définition** : Une ligne représente une note de bas de page liée à une mesure spécifique.
- **Clé composite** : `CountryCode` + `SeriesCode` + `Year`
- **Contenu** : Une explication textuelle (`DESCRIPTION`) pour justifier une anomalie ou une estimation pour une année donnée.

EdStatsData.csv

- **Définition** : Une ligne représente l'évolution historique d'un indicateur pour un pays.
- **Clé composite** : `CountryCode` + `IndicatorCode`
- **Contenu** : Contrairement aux autres, ce fichier est "large" dans un format `pivoté` : il contient les valeurs numériques pour chaque année de 1970 à 2100 sur la même ligne.

```
display(Markdown(f"## Analyse du fichier : {dataframes[0]['name']}"))
```

Analyse du fichier : EdStatsCountry.csv

> **Note technique .shape :**
>
> - **Fonctionnement** : Contrairement à une méthode, .shape est un attribut (propriété) du DataFrame. Il ne prend pas de parenthèses (). Il renvoie un tuple contenant deux éléments : (nombre_de_lignes, nombre_de_colonnes).
> - **utilité** : C'est le premier indicateur de la complexité du fichier. Il permet également de valider l'impact de nos futurs filtrages en comparant les dimensions "avant" et

> "après".

```
rows, columns = dataframes[0]['data'].shape
print(f"Rows: {rows}, Columns: {columns}")
display(Markdown(f"### 3.2. Le fichier : {dataframes[0]['name']} comprend {rows} ligne
```

3.2. Le fichier : EdStatsCountry.csv comprend 241 lignes et 32 colonnes

> **Traitement des redondances**
>
> - **.duplicated()** : Cette méthode parcourt le DataFrame et renvoie un masque booléen (une série de `True` ou `False`). Elle marque True pour chaque ligne dont toutes les valeurs sont strictement identiques à une ligne précédente.
> - **.sum()** : En Python, les valeurs booléennes sont traitées numériquement (`True = 1` et `False = 0`). En appliquant `.sum()` sur le résultat de duplicated(), nous obtenons instantanément le nombre total de lignes dupliquées.

```
duplicate_count = dataframes[0]['data'].duplicated().sum()
display(Markdown(f"### 3.3. Le fichier : {dataframes[0]['name']} posséde {duplicate_c
```

3.3. Le fichier : EdStatsCountry.csv posséde 0 lignes dupliquées

> - **.drop_duplicates()** : Si le compte est supérieur à zéro, cette méthode permet de supprimer les copies pour ne conserver qu'une seule occurrence unique de chaque ligne.

```
if duplicate_count > 0:
    dataframes[0]['data'] = dataframes[0]['data'].drop_duplicates()
```

3.4. Calcul du pourcentage de valeurs manquantes par colonnes et affichage dans un nouveau dataframe trié par pourcentage décroissant.

> **Analyse de la complétude** :
>
> - **.isnull() ou .isna()** : Cette méthode génère un masque booléen où chaque cellule vide (NaN) est marquée comme True.
> - **len()** : En divisant la somme des valeurs nulles par la longueur totale du DataFrame (`len(df)`), nous obtenons une proportion que nous multiplions par 100 pour obtenir un pourcentage lisible.
> - **pd.DataFrame()** : Nous reconstruisons un nouveau tableau pour synthétiser ces résultats, ce qui facilite la lecture par rapport à une simple liste brute.
> - **.sort_values()** : Cette méthode permet de trier le résultat. En utilisant ascending=False, nous plaçons les colonnes les plus vides en haut de tableau

> pour identifier immédiatement les variables inutilisables.

```
percent_missing = dataframes[0]['data'].isnull().sum() * 100 / len(dataframes[0]['data
missing_value = pd.DataFrame({'column_name' : dataframes[0]['data'].columns, 'percent_
display(missing_value)
```

	column_name	percent_missing
Unnamed: 31	Unnamed: 31	100.000000
National accounts reference year	National accounts reference year	86.721992
Alternative conversion factor	Alternative conversion factor	80.497925
Other groups	Other groups	75.933610
Latest industrial data	Latest industrial data	55.601660
Vital registration complete	Vital registration complete	53.941909
External debt Reporting status	External debt Reporting status	48.547718
Latest household survey	Latest household survey	41.493776
Latest agricultural census	Latest agricultural census	41.078838
Lending category	Lending category	40.248963
PPP survey year	PPP survey year	39.834025
Special Notes	Special Notes	39.834025
Source of most recent Income and expenditure data	Source of most recent Income and expenditure data	33.609959
Government Accounting concept	Government Accounting concept	33.195021
Latest water withdrawal data	Latest water withdrawal data	25.726141
IMF data dissemination standard	IMF data dissemination standard	24.896266
Balance of Payments Manual in use	Balance of Payments Manual in use	24.896266
Latest trade data	Latest trade data	23.236515
SNA price valuation	SNA price valuation	18.257261
System of trade	System of trade	17.012448
National accounts base year	National accounts base year	14.937759
Latest population census	Latest population census	11.618257
Region	Region	11.203320
Income Group	Income Group	11.203320
Currency Unit	Currency Unit	10.788382
System of National Accounts	System of National Accounts	10.788382
2-alpha code	2-alpha code	1.244813
WB-2 code	WB-2 code	0.414938
Long Name	Long Name	0.000000
Short Name	Short Name	0.000000
Table Name	Table Name	0.000000

	column_name	percent_missing
Country Code	Country Code	0.000000

3.5. Néttoyage des collones atteignant plus de 90% de valeurs manquantes

> **Optimisation du Data Set**
>
> - **.dropna() avec un seuil** : axis=1 : Ce paramètre indique à Pandas d'agir sur les colonnes (l'axe vertical) plutôt que sur les lignes.
> - **thresh=limit** : C'est le paramètre de seuil (threshold). Il définit le nombre minimum de valeurs non-nulles requises pour que la colonne soit conservée.
> - **Logique de calcul** : Si on définis limit à 10% de la longueur totale (len(df) * 0.1), toute colonne ayant plus de 90% de données manquantes sera supprimée.
> - **Utilité** : Cette méthode est plus robuste que de supprimer les colonnes par leur nom, car elle s'adapte dynamiquement au contenu réel de chaque fichier sans hardcoding.

```
limit = len(dataframes[0]['data']) * 0.1
dataframes[0]['data'] = dataframes[0]['data'].dropna(axis=1, thresh=limit)
display(dataframes[0]['data'].head())
```

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Income Group
0	ABW	Aruba	Aruba	Aruba	AW	Aruban florin	SNA data for 2000-2011 are updated from offici...	Latin America & Caribbean	High income: nonOECD
1	AFG	Afghanistan	Afghanistan	Islamic State of Afghanistan	AF	Afghan afghani	Fiscal year end: March 20; reporting period fo...	South Asia	Low income
2	AGO	Angola	Angola	People's Republic of Angola	AO	Angolan kwanza	April 2013 database update: Based on IMF data,...	Sub-Saharan Africa	Upper middle income
3	ALB	Albania	Albania	Republic of Albania	AL	Albanian lek	NaN	Europe & Central Asia	Upper middle income
4	AND	Andorra	Andorra	Principality of Andorra	AD	Euro	NaN	Europe & Central Asia	High income: nonOECD

5 rows × 31 columns

```
display(Markdown(f"### 3.6.1. Obtention des mesures de tendances centrales et de dispe
```

3.6.1. Obtention des mesures de tendances centrales et de dispersions : EdStatsCountry.csv

> **Analyse descriptive (Numerical feature)** :
>
> - **select_dtypes(include=['number'])** : Cette méthode filtre le DataFrame pour ne conserver que les colonnes de type numérique (entiers ou flottants). C'est une

> sécurité indispensable avant de lancer des calculs mathématiques qui échoueraient sur du texte.
> - **.empty** : Un attribut qui renvoie True si le DataFrame résultant ne contient aucune donnée. Nous l'utilisons pour conditionner l'affichage et éviter des erreurs de rendu.
> - **.describe()** : La fonction maîtresse de l'analyse descriptive. Elle génère automatiquement un tableau de synthèse incluant :
> - count : Le nombre de valeurs renseignées (non-nulles).
> - mean : La moyenne arithmétique.
> - std : L'écart-type, mesurant la dispersion des données autour de la moyenne.
> - min / max : Les valeurs extrêmes du jeu de données.
> - 25%, 50% (médiane), 75% : Les quartiles, permettant de comprendre la répartition des données.

```
numeric_df = dataframes[0]['data'].select_dtypes(include=['number'])

if not numeric_df.empty:
    display(dataframes[0]['data'].describe(include=[np.number]))
else :
    display(Markdown(f" Le fichier : {dataframes[0]['name']} ne posséde pas de valeur
```

	National accounts reference year	Latest industrial data	Latest trade data
count	32.00000	107.000000	185.000000
mean	2001.53125	2008.102804	2010.994595
std	5.24856	2.616834	2.569675
min	1987.00000	2000.000000	1995.000000
25%	1996.75000	2007.500000	2011.000000
50%	2002.00000	2009.000000	2012.000000
75%	2005.00000	2010.000000	2012.000000
max	2012.00000	2010.000000	2012.000000

```
df_source = dataframes[0]['data']
cat_cols = df_source.select_dtypes(include=['object', 'string']).columns

report_chunks = []

for col in cat_cols:
    counts = df_source[col].value_counts().head(5).to_frame()

    counts = counts.reset_index()
    counts.columns = ['Valeur', 'Nombre']
    counts.insert(0, 'Variable', col)
    report_chunks.append(counts)

final_report = pd.concat(report_chunks, ignore_index=True)
```

```
display(Markdown(f"### 3.6.2. Rapport global des occurrences : {dataframes[0]['name']}
```

3.6.2. Rapport global des occurrences : EdStatsCountry.csv

> **Analyse des variables catégorielles**
>
> - **select_dtypes(include=['object', 'string'])** : Cette méthode cible exclusivement les colonnes textuelles (catégorielles).
> - **value_count().head(5)** : Pour chaque colonne, nous calculons la fréquence d'apparition de chaque texte et ne conservons que le "Top 5".
> - **reset_index et insert()** : Ces manipulations permettent de transformer un résultat de calcul (Series) en un tableau propre, en réintégrant le nom de la variable d'origine comme une colonne à part entière.
> - **pd.concat()** : Cette fonction est l'équivalent d'un "collage" de tableaux. Elle rassemble tous les petits rapports individuels (report_chunks) en un seul grand DataFrame final pour une lecture centralisée.
> - **pd.option_context** : C'est un "gestionnaire de contexte" (utilisé avec le mot-clé with). Il permet de modifier temporairement les réglages de Pandas uniquement pour le bloc de code qui suit.
> - **'display.max_rows'** : En réglant cette option sur None, on indique à Pandas qu'il n'y a plus de limite au nombre de lignes à afficher.
> - **Avantage** : Une fois sorti du bloc with, Pandas reprend ses réglages par défaut, ce qui évite d'encombrer le Notebook pour les autres affichages plus petits.

```
with pd.option_context('display.max_rows', None):
    display(final_report)
```

	Variable	Valeur	Nombre
0	Country Code	ABW	1
1	Country Code	AFG	1
2	Country Code	AGO	1
3	Country Code	ALB	1
4	Country Code	AND	1
5	Short Name	Aruba	1
6	Short Name	Afghanistan	1
7	Short Name	Angola	1
8	Short Name	Albania	1
9	Short Name	Andorra	1
10	Table Name	Aruba	1
11	Table Name	Afghanistan	1
12	Table Name	Angola	1
13	Table Name	Albania	1
14	Table Name	Andorra	1
15	Long Name	Aruba	1
16	Long Name	Islamic State of Afghanistan	1
17	Long Name	People's Republic of Angola	1
18	Long Name	Republic of Albania	1
19	Long Name	Principality of Andorra	1
20	2-alpha code	AW	1
21	2-alpha code	AF	1
22	2-alpha code	AO	1
23	2-alpha code	AL	1
24	2-alpha code	AD	1
25	Currency Unit	Euro	23
26	Currency Unit	U.S. dollar	14
27	Currency Unit	CFA franc	14
28	Currency Unit	East Caribbean dollar	6
29	Currency Unit	Australian dollar	3
30	Special Notes	April 2012 database update: Based on official ...	6

	Variable	Valeur	Nombre
31	Special Notes	Fiscal year end: March 31; reporting period fo...	4
32	Special Notes	Fiscal year end: June 30; reporting period for...	3
33	Special Notes	Fiscal year end: June 30; reporting period for...	2
34	Special Notes	April 2013 database update: Based on IMF data,...	2
35	Region	Europe & Central Asia	57
36	Region	Sub-Saharan Africa	48
37	Region	Latin America & Caribbean	41
38	Region	East Asia & Pacific	36
39	Region	Middle East & North Africa	21
40	Income Group	Upper middle income	55
41	Income Group	Lower middle income	50
42	Income Group	High income: nonOECD	44
43	Income Group	Low income	34
44	Income Group	High income: OECD	31
45	WB-2 code	AW	1
46	WB-2 code	AF	1
47	WB-2 code	AO	1
48	WB-2 code	AL	1
49	WB-2 code	AD	1
50	National accounts base year	2005	34
51	National accounts base year	Original chained constant price data are resca...	28
52	National accounts base year	2000	25
53	National accounts base year	2006	19
54	National accounts base year	1990	11
55	SNA price valuation	Value added at basic prices (VAB)	163
56	SNA price valuation	Value added at producer prices (VAP)	34
57	Lending category	IBRD	67
58	Lending category	IDA	59
59	Lending category	Blend	18

	Variable	Valeur	Nombre
60	Other groups	HIPC	40
61	Other groups	Euro area	18
62	System of National Accounts	Country uses the 1993 System of National Accou...	165
63	System of National Accounts	Country uses the 1968 System of National Accou...	42
64	System of National Accounts	Country uses the 2008 System of National Accou...	8
65	Alternative conversion factor	1990–95	8
66	Alternative conversion factor	1987–95	5
67	Alternative conversion factor	1993	3
68	Alternative conversion factor	1992–95	2
69	Alternative conversion factor	1991	2
70	PPP survey year	2005	98
71	PPP survey year	Rolling	37
72	PPP survey year	2011	10
73	Balance of Payments Manual in use	IMF Balance of Payments Manual, 6th edition.	181
74	External debt Reporting status	Actual	107
75	External debt Reporting status	Estimate	11
76	External debt Reporting status	Preliminary	6
77	System of trade	General trade system	106
78	System of trade	Special trade system	94
79	Government Accounting concept	Consolidated central government	95
80	Government Accounting concept	Budgetary central government	66
81	IMF data dissemination standard	General Data Dissemination System (GDDS)	110
82	IMF data dissemination standard	Special Data Dissemination Standard (SDDS)	71
83	Latest population census	2011	59
84	Latest population census	2010	49
85	Latest population census	2012	18
86	Latest population census	2009	14
87	Latest population census	2008	9

	Variable	Valeur	Nombre
88	Latest household survey	Multiple Indicator Cluster Survey (MICS), 2012	10
89	Latest household survey	World Health Survey (WHS), 2003	10
90	Latest household survey	Demographic and Health Survey (DHS), 2013	10
91	Latest household survey	Multiple Indicator Cluster Survey (MICS), 2011	9
92	Latest household survey	Multiple Indicator Cluster Survey (MICS), 2010	9
93	Source of most recent Income and expenditure data	Integrated household survey (IHS), 2012	15
94	Source of most recent Income and expenditure data	Integrated household survey (IHS), 2010	9
95	Source of most recent Income and expenditure data	Integrated household survey (IHS), 2011	9
96	Source of most recent Income and expenditure data	Integrated household survey (IHS), 2008	7
97	Source of most recent Income and expenditure data	Expenditure survey/budget survey (ES/BS), 2012	7
98	Vital registration complete	Yes	110
99	Vital registration complete	Yes. Vital registration for Guernsey and Jersey.	1
100	Latest agricultural census	2010	36
101	Latest agricultural census	2007	16
102	Latest agricultural census	2013	13
103	Latest agricultural census	2012	10
104	Latest agricultural census	2011	9
105	Latest water withdrawal data	2000	40
106	Latest water withdrawal data	2005	40
107	Latest water withdrawal data	2007	18
108	Latest water withdrawal data	2002	16
109	Latest water withdrawal data	2009	12

```
display(Markdown(f"## Analyse du fichier : {dataframes[1]['name']}"))
```

Analyse du fichier : EdStatsCountry-Series.csv

```
rows, columns = dataframes[1]['data'].shape
print(f"Rows: {rows}, Columns: {columns}")
display(Markdown(f"### 3.2. Le fichier : {dataframes[1]['name']} comprend {rows} ligne
```

3.2. Le fichier : EdStatsCountry-Series.csv comprend 613 lignes et 4 colonnes

```
duplicate_count = dataframes[1]['data'].duplicated().sum()
display(Markdown(f"### 3.3. Le fichier : {dataframes[1]['name']} posséde {duplicate_c
```

3.3. Le fichier : EdStatsCountry-Series.csv posséde 0 lignes dupliquées

```
if duplicate_count > 0:
    dataframes[1]['data'] = dataframes[1]['data'].drop_duplicates()
```

3.4. Calcul du pourcentage de valeurs manquantes par colonnes et affichage dans un nouveau dataframe trié par pourcentage décroissant.

```
percent_missing = dataframes[1]['data'].isnull().sum() * 100 / len(dataframes[1]['data
missing_value = pd.DataFrame({'column_name' : dataframes[1]['data'].columns, 'percent_
display(missing_value)
```

	column_name	percent_missing
Unnamed: 3	Unnamed: 3	100.0
CountryCode	CountryCode	0.0
SeriesCode	SeriesCode	0.0
DESCRIPTION	DESCRIPTION	0.0

3.5. Néttoyage des collones atteignant plus de 90% de valeurs manquantes

```
limit = len(dataframes[1]['data']) * 0.1
dataframes[1]['data'] = dataframes[1]['data'].dropna(axis=1, thresh=limit)
display(dataframes[1]['data'].head())
```

	CountryCode	SeriesCode	DESCRIPTION
0	ABW	SP.POP.TOTL	Data sources : United Nations World Population...
1	ABW	SP.POP.GROW	Data sources: United Nations World Population ...
2	AFG	SP.POP.GROW	Data sources: United Nations World Population ...
3	AFG	NY.GDP.PCAP.PP.CD	Estimates are based on regression.
4	AFG	SP.POP.TOTL	Data sources : United Nations World Population...

```
display(Markdown(f"### 3.6.1. Obtention des mesures de tendances centrales et de dispe
```

3.6.1. Obtention des mesures de tendances centrales et de dispersions : EdStatsCountry-Series.csv

```
numeric_df = dataframes[1]['data'].select_dtypes(include=['number'])

if not numeric_df.empty:
    display(dataframes[1]['data'].describe(include=[np.number]))
else :
    display(Markdown(f" Le fichier : {dataframes[1]['name']} ne posséde pas de valeur
```

Le fichier : EdStatsCountry-Series.csv ne posséde pas de valeur numérique

```
df_source = dataframes[1]['data']
cat_cols = df_source.select_dtypes(include=['object', 'string']).columns

report_chunks = []

for col in cat_cols:
    counts = df_source[col].value_counts().head(5).to_frame()

    counts = counts.reset_index()
    counts.columns = ['Valeur', 'Nombre']
    counts.insert(0, 'Variable', col)
    report_chunks.append(counts)

final_report = pd.concat(report_chunks, ignore_index=True)

display(Markdown(f"### 3.6.2. Rapport global des occurrences : {dataframes[1]['name']
```

3.6.2. Rapport global des occurrences : EdStatsCountry-Series.csv

```
with pd.option_context('display.max_rows', None):
    display(final_report)
```

	Variable	Valeur	Nombre
0	CountryCode	GEO	18
1	CountryCode	MDA	18
2	CountryCode	CYP	12
3	CountryCode	MAR	12
4	CountryCode	MUS	12
5	SeriesCode	SP.POP.TOTL	211
6	SeriesCode	SP.POP.GROW	211
7	SeriesCode	NY.GDP.PCAP.PP.CD	19
8	SeriesCode	NY.GDP.PCAP.PP.KD	19
9	SeriesCode	NY.GNP.PCAP.PP.CD	19
10	DESCRIPTION	Data sources : United Nations World Population...	154
11	DESCRIPTION	Data sources: United Nations World Population ...	137
12	DESCRIPTION	Estimates are based on regression.	84
13	DESCRIPTION	Data sources : Eurostat	54
14	DESCRIPTION	Derived using ratio of age group from WPP and ...	24

```
display(Markdown(f"## Analyse du fichier : {dataframes[2]['name']}"))
```

Analyse du fichier : EdStatsData.csv

```
rows, columns = dataframes[2]['data'].shape
print(f"Rows: {rows}, Columns: {columns}")
display(Markdown(f"### 3.2. Le fichier : {dataframes[2]['name']} comprend {rows} ligne
```

3.2. Le fichier : EdStatsData.csv comprend 886930 lignes et 70 colonnes

```
duplicate_count = dataframes[2]['data'].duplicated().sum()
display(Markdown(f"### 3.3. Le fichier : {dataframes[2]['name']} posséde {duplicate_c
```

3.3. Le fichier : EdStatsData.csv posséde 0 lignes dupliquées

```
if duplicate_count > 0:
    dataframes[2]['data'] = dataframes[2]['data'].drop_duplicates()
```

3.4. Calcul du pourcentage de valuers manquantes par colonnes et affichage dans un nouveau dataframe trié par pourcentage décroissant

```
percent_missing = dataframes[2]['data'].isnull().sum() * 100 / len(dataframes[2]['data
missing_value = pd.DataFrame({'column_name' : dataframes[2]['data'].columns, 'percent_
display(missing_value)
```

	column_name	percent_missing
Unnamed: 69	Unnamed: 69	100.000000
2017	2017	99.983877
2016	2016	98.144160
1971	1971	95.993258
1973	1973	95.992356
...	...	...
2010	2010	72.665036
Country Code	Country Code	0.000000
Indicator Code	Indicator Code	0.000000
Indicator Name	Indicator Name	0.000000
Country Name	Country Name	0.000000

70 rows × 2 columns

3.5. Nettoyage des collones atteignant plus de 90% de valuers manquantes

```
limit = len(dataframes[3]['data']) * 0.1
dataframes[2]['data'] = dataframes[2]['data'].dropna(axis=1, thresh=limit)
display(dataframes[2]['data'].head())
```

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1975	1980	1985	
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	
1	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	
2	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	
3	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	NaN	
4	Arab World	ARB	Adjusted net enrolment rate, primary, both sex...	SE.PRM.TENR	54.822121	59.36554	65.617767	69.033211	71.9

5 rows × 34 columns

Observation des données brutes:

L'analyse du taux de valeurs manquantes (Missing Values) montre des seuils critiques pour les années post-2015:

- **2016** : 98,14 % de données manquantes.
- **2017** : 99,98 % de données manquantes.
- **2018 - 2027** : Taux de vacuité proche de 100 % pour les indicateurs thématiques sélectionnés (Education, IT, Learning Outcomes).

```
display(Markdown(f"### 3.6.1. Obtention des mesures de tendances centrales et de dispe
```

3.6.1. Obtention des mesures de tendances centrales et de dispersions : EdStatsData.csv

```
numeric_df = dataframes[2]['data'].select_dtypes(include=['number'])

if not numeric_df.empty:
    display(dataframes[2]['data'].describe(include=[np.number]))
else :
    display(Markdown(f" Le fichier : {dataframes[2]['name']} ne posséde pas de valeur
```

	1970	1975	1980	1985	1990	19
count	7.228800e+04	8.730600e+04	8.912200e+04	9.029600e+04	1.244050e+05	7.443700e+
mean	1.974772e+09	2.314288e+09	3.283898e+09	3.622763e+09	9.084424e+09	1.571674e-
std	1.211687e+11	1.375059e+11	1.780774e+11	2.002929e+11	3.665667e+11	4.881357e-
min	-1.435564e+00	-3.658569e+00	-1.404240e+00	-2.216315e+00	-1.803750e+00	-5.814339e+
25%	8.900000e-01	1.400000e+00	1.770000e+00	2.150000e+00	4.830000e+00	5.134554e-
50%	6.317724e+00	9.677420e+00	1.107000e+01	1.200000e+01	5.048379e+01	3.916000e+
75%	6.251250e+01	7.854163e+01	8.202760e+01	8.338313e+01	9.134300e+04	4.383130e+
max	1.903929e+13	2.300634e+13	2.784319e+13	3.166465e+13	4.714344e+13	4.781272e-

8 rows × 30 columns

3.6. Note sur l'analyse descriptive de EdStatsData.csv

Bien que la méthode `.describe()` s'exécute sans erreur technique sur ce fichier, les résultats statistiques globaux (moyenne, écart-type) sont **analytiquement inutilisables** en l'état pour les raisons suivantes :

- **Hétérogénéité des indicateurs (*Mixed Scales*)** : Chaque colonne "Année" mélange des données de natures totalement différentes. Faire la moyenne entre un PIB (en milliers de milliards), une population (en milliards) et un taux d'alphabétisation (en pourcentage) génère un chiffre dépourvu de sens métier.
- **Biais de dispersion (*Variance Bias*)** : L'écart-type (*standard deviation*) extrêmement élevé observé dans les résultats (ex: 1.2×10^{11} pour 1970) confirme que les données ne suivent pas une distribution commune. Ce "bruit" statistique masque la réalité de chaque indicateur individuel.
- **Interprétation** : Pour obtenir des statistiques descriptives cohérentes, il est impératif d'effectuer un **filtrage préalable** sur la colonne `Indicator Code` afin d'isoler une seule métrique avant d'appliquer des calculs d'agrégation.

> **Conclusion de l'audit** : Ce tableau global n'est conservé ici qu'à titre de validation technique de la lecture des données numériques. Ce jeu de données servira exclusivement de base à une analyse par filtrage sélectif (méthodes `.loc` ou `.query`). Cette approche est la seule permettant de garantir la pertinence des calculs en isolant chaque métrique de son contexte d'origine.

```
df_source = dataframes[1]['data']
cat_cols = df_source.select_dtypes(include=['object', 'string']).columns

report_chunks = []

for col in cat_cols:
    counts = df_source[col].value_counts().head(5).to_frame()

    counts = counts.reset_index()
    counts.columns = ['Valeur', 'Nombre']
    counts.insert(0, 'Variable', col)
    report_chunks.append(counts)

final_report = pd.concat(report_chunks, ignore_index=True)

display(Markdown(f"### 3.6.2. Rapport global des occurrences : {dataframes[1]['name']}
```

3.6.2. Rapport global des occurrences : EdStatsCountry-Series.csv

```
with pd.option_context('display.max_rows', None):
    display(final_report)
```

	Variable	Valeur	Nombre
0	CountryCode	GEO	18
1	CountryCode	MDA	18
2	CountryCode	CYP	12
3	CountryCode	MAR	12
4	CountryCode	MUS	12
5	SeriesCode	SP.POP.TOTL	211
6	SeriesCode	SP.POP.GROW	211
7	SeriesCode	NY.GDP.PCAP.PP.CD	19
8	SeriesCode	NY.GDP.PCAP.PP.KD	19
9	SeriesCode	NY.GNP.PCAP.PP.CD	19
10	DESCRIPTION	Data sources : United Nations World Population...	154
11	DESCRIPTION	Data sources: United Nations World Population ...	137
12	DESCRIPTION	Estimates are based on regression.	84
13	DESCRIPTION	Data sources : Eurostat	54
14	DESCRIPTION	Derived using ratio of age group from WPP and ...	24

```
display(Markdown(f"## Analyse du fichier : {dataframes[2]['name']}"))
```

Analyse du fichier : EdStatsData.csv

```
rows, columns = dataframes[3]['data'].shape
print(f"Rows: {rows}, Columns: {columns}")
display(Markdown(f"### 3.2. Le fichier : {dataframes[3]['name']} comprend {rows} ligne
```

3.2. Le fichier : EdStatsFootNote.csv comprend 643638 lignes et 5 colonnes

```
duplicate_count = dataframes[3]['data'].duplicated().sum()
display(Markdown(f"### 3.3. Le fichier : {dataframes[3]['name']} posséde {duplicate_c
```

3.3. Le fichier : EdStatsFootNote.csv posséde 0 lignes dupliquées

```
if duplicate_count > 0:
    dataframes[3]['data'] = dataframes[3]['data'].drop_duplicates()
```

3.4. Calcul du pourcentage de valuers manquantes par colonnes et affichage dans un nouveau dataframe trié par pourcentage décroissant

```
percent_missing = dataframes[3]['data'].isnull().sum() * 100 / len(dataframes[3]['data
missing_value = pd.DataFrame({'column_name' : dataframes[3]['data'].columns, 'percent_
display(missing_value)
```

	column_name	percent_missing
Unnamed: 4	Unnamed: 4	100.0
CountryCode	CountryCode	0.0
SeriesCode	SeriesCode	0.0
Year	Year	0.0
DESCRIPTION	DESCRIPTION	0.0

3.5. Nettoyage des collones atteignant plus de 90% de valuers manquantes

```
limit = len(dataframes[3]['data']) * 0.1
dataframes[3]['data'] = dataframes[3]['data'].dropna(axis=1, thresh=limit)
display(dataframes[3]['data'].head())
```

	CountryCode	SeriesCode	Year	DESCRIPTION
0	ABW	SE.PRE.ENRL.FE	YR2001	Country estimation.
1	ABW	SE.TER.TCHR.FE	YR2005	Country estimation.
2	ABW	SE.PRE.TCHR.FE	YR2000	Country estimation.
3	ABW	SE.SEC.ENRL.GC	YR2004	Country estimation.
4	ABW	SE.PRE.TCHR	YR2006	Country estimation.

```
display(Markdown(f"### 3.6.1. Obtention des mesures de tendances centrales et de dispe
```

3.6.1. Obtention des mesures de tendances centrales et de dispersions : EdStatsFootNote.csv

```
numeric_df = dataframes[3]['data'].select_dtypes(include=['number'])

if not numeric_df.empty:
    display(dataframes[3]['data'].describe(include=[np.number]))
else :
    display(Markdown(f" Le fichier : {dataframes[3]['name']} ne posséde pas de valeur
```

Le fichier : EdStatsFootNote.csv ne posséde pas de valeur numérique

```
df_source = dataframes[3]['data']
cat_cols = df_source.select_dtypes(include=['object', 'string']).columns

report_chunks = []

for col in cat_cols:
    counts = df_source[col].value_counts().head(5).to_frame()

    counts = counts.reset_index()
    counts.columns = ['Valeur', 'Nombre']
    counts.insert(0, 'Variable', col)
    report_chunks.append(counts)

final_report = pd.concat(report_chunks, ignore_index=True)

display(Markdown(f"### 3.6.2. Rapport global des occurrences : {dataframes[3]['name']
```

3.6.2. Rapport global des occurrences : EdStatsFootNote.csv

```
with pd.option_context('display.max_rows', None):
    display(final_report)
```

	Variable	Valeur	Nombre
0	CountryCode	LIC	7320
1	CountryCode	CYP	7183
2	CountryCode	LDC	6481
3	CountryCode	SSA	6389
4	CountryCode	SSF	6336
5	SeriesCode	SH.DYN.MORT	9226
6	SeriesCode	SE.PRM.AGES	8771
7	SeriesCode	SE.PRM.DURS	8771
8	SeriesCode	SE.SEC.DURS	8619
9	SeriesCode	SE.SEC.AGES	8581
10	Year	YR2004	27128
11	Year	YR2005	25992
12	Year	YR2002	25687
13	Year	YR2003	25683
14	Year	YR2000	25093
15	DESCRIPTION	Country Data	191188
16	DESCRIPTION	UNESCO Institute for Statistics (UIS) estimate	171527
17	DESCRIPTION	Estimated	117155
18	DESCRIPTION	UIS Estimation	31395
19	DESCRIPTION	Country estimation.	26308

```
display(Markdown(f"## Analyse du fichier : {dataframes[4]['name']}"))
```

Analyse du fichier : EdStatsSeries.csv

```
rows, columns = dataframes[4]['data'].shape
print(f"Rows: {rows}, Columns: {columns}")
display(Markdown(f"### 3.2. Le fichier : {dataframes[4]['name']} comprend {rows} ligne
```

3.2. Le fichier : EdStatsSeries.csv comprend 3665 lignes et 21 colonnes

```
duplicate_count = dataframes[4]['data'].duplicated().sum()
display(Markdown(f"### 3.3. Le fichier : {dataframes[4]['name']} posséde {duplicate_c
```

3.3. Le fichier : EdStatsSeries.csv posséde 0 lignes dupliquées

```
if duplicate_count > 0:
    dataframes[4]['data'] = dataframes[4]['data'].drop_duplicates()
```

3.4. Calcul du pourcentage de valuers manquantes par colonnes et affichage dans un nouveau dataframe trié par pourcentage décroissant

```
percent_missing = dataframes[4]['data'].isnull().sum() * 100 / len(dataframes[4]['data
missing_value = pd.DataFrame({'column_name' : dataframes[4]['data'].columns, 'percent_
display(missing_value)
```

	column_name	percent_missing
Unnamed: 20	Unnamed: 20	100.000000
Notes from original source	Notes from original source	100.000000
License Type	License Type	100.000000
Related indicators	Related indicators	100.000000
Other web links	Other web links	100.000000
Unit of measure	Unit of measure	100.000000
Development relevance	Development relevance	99.918145
General comments	General comments	99.618008
Limitations and exceptions	Limitations and exceptions	99.618008
Statistical concept and methodology	Statistical concept and methodology	99.372442
Aggregation method	Aggregation method	98.717599
Periodicity	Periodicity	97.298772
Related source links	Related source links	94.133697
Base Period	Base Period	91.432469
Other notes	Other notes	84.938608
Short definition	Short definition	41.173261
Topic	Topic	0.000000
Source	Source	0.000000
Long definition	Long definition	0.000000
Indicator Name	Indicator Name	0.000000
Series Code	Series Code	0.000000

3.5. Nettoyage des collones atteignant plus de 90% de valuers manquantes

```
limit = len(dataframes[4]['data']) * 0.1
dataframes[4]['data'] = dataframes[4]['data'].dropna(axis=1, thresh=limit)
display(dataframes[4]['data'].head())
```

	Series Code	Topic	Indicator Name	Short definition	Long definition	Other notes	Source
0	BAR.NOED.1519.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15-19 with...	Percentage of female population age 15-19 with...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
1	BAR.NOED.1519.ZS	Attainment	Barro-Lee: Percentage of population age 15-19 ...	Percentage of population age 15-19 with no edu...	Percentage of population age 15-19 with no edu...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
2	BAR.NOED.15UP.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15+ with n...	Percentage of female population age 15+ with n...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
3	BAR.NOED.15UP.ZS	Attainment	Barro-Lee: Percentage of population age 15+ wi...	Percentage of population age 15+ with no educa...	Percentage of population age 15+ with no educa...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
4	BAR.NOED.2024.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 20-24 with...	Percentage of female population age 20-24 with...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...

```
display(Markdown(f"### 3.6.1. Obtention des mesures de tendances centrales et de dispe
```

3.6.1. Obtention des mesures de tendances centrales et de dispersions : EdStatsSeries.csv

```
numeric_df = dataframes[4]['data'].select_dtypes(include=['number'])

if not numeric_df.empty:
    display(dataframes[4]['data'].describe(include=[np.number]))
else :
    display(Markdown(f" Le fichier : {dataframes[4]['name']} ne posséde pas de valeur
```

Le fichier : EdStatsSeries.csv ne posséde pas de valeur numérique

```
df_source = dataframes[4]['data']
cat_cols = df_source.select_dtypes(include=['object', 'string']).columns
```

```
report_chunks = []

for col in cat_cols:
    counts = df_source[col].value_counts().head(5).to_frame()

    counts = counts.reset_index()
    counts.columns = ['Valeur', 'Nombre']
    counts.insert(0, 'Variable', col)
    report_chunks.append(counts)

final_report = pd.concat(report_chunks, ignore_index=True)

display(Markdown(f"### 3.6.2. Rapport global des occurrences : {dataframes[4]['name']}
```

3.6.2. Rapport global des occurrences : EdStatsSeries.csv

```
with pd.option_context('display.max_rows', None):
    display(final_report)
```

	Variable	Valeur	Nombre
0	Series Code	BAR.NOED.1519.FE.ZS	1
1	Series Code	BAR.NOED.1519.ZS	1
2	Series Code	BAR.NOED.15UP.FE.ZS	1
3	Series Code	BAR.NOED.15UP.ZS	1
4	Series Code	BAR.NOED.2024.FE.ZS	1
5	Topic	Learning Outcomes	1046
6	Topic	Attainment	733
7	Topic	Education Equality	426
8	Topic	Secondary	256
9	Topic	Primary	248
10	Indicator Name	Barro-Lee: Percentage of female population age...	1
11	Indicator Name	Barro-Lee: Percentage of population age 15-19 ...	1
12	Indicator Name	Barro-Lee: Percentage of female population age...	1
13	Indicator Name	Barro-Lee: Percentage of population age 15+ wi...	1
14	Indicator Name	Barro-Lee: Percentage of female population age...	1
15	Short definition	Data Interpretation: 1=Latent; 2=Emerging; 3=E...	215
16	Short definition	Percentage of students who were unable to read...	51
17	Short definition	Average total number of invented/nonsense word...	51
18	Short definition	Share of students who scored zero percent on t...	51
19	Short definition	Share of students who scored 80 percent or hig...	51
20	Long definition	Data Interpretation: 1=Latent; 2=Emerging; 3=E...	215
21	Long definition	Percentage of students who were unable to read...	51
22	Long definition	Average total number of invented/nonsense word...	51
23	Long definition	Share of students who scored zero percent on t...	51
24	Long definition	Share of students who scored 80 percent or hig...	51
25	Other notes	EGRA	403
26	Other notes	Health: Population: Structure	52
27	Other notes	Single Level Attainment/ Not Cumulative	21
28	Other notes	Proficiency	20
29	Other notes	Cumulative Attainment	16
30	Source	UNESCO Institute for Statistics	1269
31	Source	Early Grade Reading Assessment (EGRA): https:/...	403

	Variable	Valeur	Nombre
32	Source	Robert J. Barro and Jong-Wha Lee: http://www.b...	360
33	Source	Wittgenstein Centre for Demography and Global ...	308
34	Source	Systems Approach for Better Education Results ...	215

4. Nettoyage des entités non-étatiques (Faux pays)

Cette étape vise à garantir la cohérence référentielle du dataset en isolant les véritables pays des agrégats statistiques (ex: World, High Income).

Méthodologie appliquée :

1. **Identification dans `EdStatsCountry.csv`** :
   - Audit de la colonne `Region` : les entités n'ayant pas d'affectation régionale sont identifiées comme des agrégats économiques ou mondiaux.
2. **Purification du référentiel** :
   - Suppression des lignes identifiées dans `EdStatsCountry.csv` pour créer une "Source de Vérité" fiable.
   - Extraction de la "Liste Blanche" : Création de la liste des Country Code valides à partir du fichier fraîchement nettoyé.
3. **Propagation du nettoyage aux autres DataFrames** :
   - **Méthode par liste :** Utilisation de la liste extraite précédemment pour filtrer les autres tables.
   - **Méthode par jointure :** Utilisation d'un `inner join` (jointure interne) pour ne conserver que les enregistrements dont la clé (`Country Code`) existe dans le référentiel nettoyé.

4.2.1. Suppression des lignes identifiées dans `EdStatsCountry.csv` pour créer une "Source de Vérité" fiable.

```
dataframes[0]['data'] = dataframes[0]['data'].dropna(subset=['Region'])
display(dataframes[0]['data'])
```

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Inc G
0	ABW	Aruba	Aruba	Aruba	AW	Aruban florin	SNA data for 2000-2011 are updated from offici...	Latin America & Caribbean	inc non
1	AFG	Afghanistan	Afghanistan	Islamic State of Afghanistan	AF	Afghan afghani	Fiscal year end: March 20; reporting period fo...	South Asia	in
2	AGO	Angola	Angola	People's Republic of Angola	AO	Angolan kwanza	April 2013 database update: Based on IMF data,...	Sub-Saharan Africa	U m in
3	ALB	Albania	Albania	Republic of Albania	AL	Albanian lek	NaN	Europe & Central Asia	U m in
4	AND	Andorra	Andorra	Principality of Andorra	AD	Euro	NaN	Europe & Central Asia	inc non
...	...	...	...	...	...	...	...	...	
236	XKX	Kosovo	Kosovo	Republic of Kosovo	NaN	Euro	Kosovo became a World Bank member on June 29, ...	Europe & Central Asia	L m in
237	YEM	Yemen	Yemen, Rep.	Republic of Yemen	YE	Yemeni rial	Based on official government statistics and In...	Middle East & North Africa	L m in
238	ZAF	South Africa	South Africa	Republic of South Africa	ZA	South African rand	Fiscal year end: March 31; reporting period fo...	Sub-Saharan Africa	U m in
239	ZMB	Zambia	Zambia	Republic of Zambia	ZM	New Zambian	National accounts	Sub-Saharan	L m

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Inc G
						kwacha	data have rebased to reflect...	Africa	in
240	ZWE	Zimbabwe	Zimbabwe	Republic of Zimbabwe	ZW	U.S. dollar	Fiscal year end: June 30; reporting period for...	Sub-Saharan Africa	in

214 rows × 31 columns

4.2.2. Extraction de la "Liste Blanche" : Création de la liste des Country Code valides à partir du fichier fraîchement nettoyé.

> **Extraction de la 'white list'** :
>
> - **.unique()** : Cette méthode de Pandas identifie toutes les valeurs distinctes dans une colonne. Elle élimine les doublons potentiels et renvoie un objet de type Numpy Array.
> - **.tolist()** : Comme son nom l'indique, cette méthode convertit l'objet Pandas/Numpy en une liste standard Python. C'est une étape cruciale car les listes Python sont plus simples à manipuler pour les opérations de filtrage itératives.
> - **[:5] (Slicing)** : Puisque la liste contient des centaines d'éléments, nous utilisons le découpage (slicing) pour n'afficher que les 5 premiers. Cela permet de valider visuellement le format des données (ex: ['ABW', 'AFG', ...]) sans encombrer le Notebook.

```
list_countryCode = dataframes[0]['data']['Country Code'].unique().tolist()
display(list_countryCode[:5])
```

```
['ABW', 'AFG', 'AGO', 'ALB', 'AND']
```

4.3.1. Utilisation de la liste extraite précédemment pour filtrer les autres tables.

```
display(Markdown(f" Nombre de lignes avant filtrage pour le fichier {dataframes[1]['na
```

Nombre de lignes avant filtrage pour le fichier EdStatsCountry-Series.csv : 613

> **Filtrage par appartenance**

- **.isin()** : .isin(liste) : Cette méthode est un filtre puissant qui compare chaque valeur d'une colonne avec une liste de référence. Elle renvoie True si la valeur est présente dans la liste, et False sinon.
- **Indexation booléenne** : En plaçant ce filtre entre crochets df[mask], Pandas ne conserve que les lignes où la condition est True. Ici, cela permet d'éliminer instantanément toutes les lignes correspondant à des agrégats ou à des entités non-étatiques.
- **Réaffectation** : En réaffectant le résultat à `dataframes[1]['data']`, nous mettons à jour le DataFrame en mémoire avec sa version nettoyée.
- .head() : Comme vu précédemment, nous terminons par un affichage des premières lignes pour confirmer visuellement que le format des données reste cohérent après le filtrage.

```
dataframes[1]['data'] = dataframes[1]['data'][dataframes[1]['data']['CountryCode'].is
display(dataframes[1]['data'].head())
```

	CountryCode	SeriesCode	DESCRIPTION
0	ABW	SP.POP.TOTL	Data sources : United Nations World Population...
1	ABW	SP.POP.GROW	Data sources: United Nations World Population ...
2	AFG	SP.POP.GROW	Data sources: United Nations World Population ...
3	AFG	NY.GDP.PCAP.PP.CD	Estimates are based on regression.
4	AFG	SP.POP.TOTL	Data sources : United Nations World Population...

```
display(Markdown(f" Nombre de lignes aprés filtrage pour le fichier {dataframes[1]['na
```

Nombre de lignes aprés filtrage pour le fichier EdStatsCountry-Series.csv : 611

```
display(Markdown(f" Nombre de lignes avant filtrage pour le fichier {dataframes[2]['na
```

Nombre de lignes avant filtrage pour le fichier EdStatsData.csv : 886930

```
dataframes[2]['data'] = dataframes[2]['data'][dataframes[2]['data']['Country Code'].is
display(dataframes[2]['data'].head())
```

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1975	1980	1985	1990	1991	.
91625	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN	NaN	.
91626	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	NaN	NaN	.
91627	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	NaN	NaN	.
91628	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	NaN	NaN	NaN	.
91629	Afghanistan	AFG	Adjusted net enrolment rate, primary, both sex...	SE.PRM.TENR	NaN	NaN	NaN	NaN	NaN	NaN	.

5 rows × 34 columns

```
display(Markdown(f" Nombre de lignes aprés filtrage pour le fichier {dataframes[2]['na
```

Nombre de lignes aprés filtrage pour le fichier EdStatsData.csv : 784310

4.3.2. Utilisation d'un `inner join` (jointure interne) pour ne conserver que les enregistrements dont la clé (`Country Code`) existe dans le référentiel nettoyé.

```
display(Markdown(f" Nombre de lignes avant filtrage pour le fichier {dataframes[3]['na
```

Nombre de lignes avant filtrage pour le fichier EdStatsFootNote.csv : 643638

> **Synchronisation par jointure relationnelle** :

> - **.merge()** : Fonctionnement : Cette méthode réalise une jointure (join) entre deux DataFrames, à la manière d'une base de données SQL. Elle combine les colonnes de deux tableaux en se basant sur une valeur commune.
> - **how='inner** : Ce paramètre définit une jointure "interne". Pandas ne conserve que les lignes dont la clé de jointure est présente simultanément dans les deux fichiers. Les "faux pays" absents du référentiel nettoyé sont donc automatiquement éliminés.
> - **left_on et right_on** : Ces arguments sont utilisés lorsque les colonnes de jointure n'ont pas le même nom. Ici, nous lions la colonne CountryCode (sans espace) du fichier FootNote à la colonne Country Code (avec espace) du référentiel.
> - **Avantage** : Contrairement au filtrage simple, le merge permet de ramener des informations complémentaires d'une table vers une autre tout en assurant l'intégrité référentielle.

```
dataframes[3]['data'] = dataframes[3]['data'].merge(dataframes[0]['data']['Country Co
display(dataframes[3]['data'].head())
```

	CountryCode	SeriesCode	Year	DESCRIPTION	Country Code
0	ABW	SE.PRE.ENRL.FE	YR2001	Country estimation.	ABW
1	ABW	SE.TER.TCHR.FE	YR2005	Country estimation.	ABW
2	ABW	SE.PRE.TCHR.FE	YR2000	Country estimation.	ABW
3	ABW	SE.SEC.ENRL.GC	YR2004	Country estimation.	ABW
4	ABW	SE.PRE.TCHR	YR2006	Country estimation.	ABW

```
display(Markdown(f" Nombre de lignes aprés filtrage pour le fichier {dataframes[3]['na
```

Nombre de lignes aprés filtrage pour le fichier EdStatsFootNote.csv : 515752

> **Note sur `EdStatsFootNote`** : Le fichier `EdStatsFootNote.csv` contient deux colonnes `Country Code` il sera prévus de supprimer la colonne redondante.

> **Note sur le périmètre de filtrage** : Le fichier `EdStatsSeries.csv` n'est pas concerné par ce nettoyage. En tant que référentiel métier des indicateurs, il ne contient aucune dimension géographique (`Country Code`) et ses définitions restent valides pour l'ensemble du domaine d'étude.

5. Réduction du périmètre analytique

L'analyse initiale a révélé un volume d'indicateurs trop important pour une exploitation manuelle pertinente. Cette section détaille la stratégie de filtrage thématique et temporel pour répondre aux

besoins d'expansion internationale de la start-up Academy.

Méthodologie appliquée :

1. **Filtrage thématique :**
   - **Analyse des catégories :** Nous utilisons la colonne `Topic` du fichier `EdStatsSeries` pour identifier les thématiques structurantes.
   - **Critères de sélection :**
     - Inclusion des catégories liées au secondaire (Lycée) et au tertiaire (Université).
     - Inclusion des données sur l'accès aux technologies (IT) et les résultats d'apprentissage.
     - Exclusion des thématiques économiques pures ou de santé sans lien direct avec l'éducation.
   - **Impact :** Réduction du nombre de `Series Code` pour gagner en lisibilité et en performance de calcul.
   - **Catégories retenues** :
     - **Secondary & Tertiary** : Identification directe du volume de clients cibles (Lycée/Université).
     - **Learning Outcomes** : Mesure de la performance éducative réelle (besoin potentiel en soutien scolaire).
     - **Literacy** : Évaluation du socle de compétences de base de la population.
     - **Attainment** : Pour mesurer les diplômes déjà obtenus.
     - **Infrastructure: Communications** : Vérification de la faisabilité technique pour l'enseignement en ligne (connectivité).
2. **Filtrer l'ensemble des jeux de données** :
   - **Séparation des flux de traitement** :
     - Table de liaison (Country-Series) : Isolation dans des variables spécifiques pour diagnostic (résultats nuls observés).
     - Tables transactionnelles : Écrasement séléctif pour optimisation de la mémoire vive
3. **Filtrage temporel** : Filtrez l'ensemble des jeux de données pour ne garder que les indicateurs sélectionnés. **Objectif :** Se concentrer sur les données actuelles et exploitables pour une décision d'implantation immédiate.
   - **Interprétation des années futures :** Les colonnes allant de 2025 à 2100 dans EdStatsData correspondent à des projections démographiques théoriques.
   - **Hypothèse métier :** Pour une stratégie d'expansion à court et moyen terme, ces projections lointaines sont jugées hors périmètre et présentent un taux de remplissage quasi nul.
   - **Action :** Suppression des colonnes d'années futures via une liste générée dynamiquement (`np.arange`).
   - **Plage temporelle retenues** :
     - **2010 - 2019** : Fournit un historique stable pour comprendre l'évolution éducative sur le long terme.

    - **2020 - 2025** : Capture l'impact de la numérisation accélérée de l'enseignement (période COVID et post-COVID).
    - **2026 - 2027** : Offre une vision "présent et futur proche" pour la prise de décision immédiate.
4. **Filtrer le fichier Data** : Filtrer les années en conséquences de l'analyse de la plage temporelle pertinantes.

```
target_topics = [
    'Secondary',
    'Tertiary',
    'Infrastructure: Communications',
    'Learning Outcomes',
    'Attainment',
    'Literacy'
]

df_series_filtered = dataframes[4]['data'][dataframes[4]['data']['Topic'].isin(target_
valid_series_codes = df_series_filtered['Series Code'].unique().tolist()
```

5.1. Filtrage thématique

Nous extrayons les codes d'indicateurs (`Series Code`) issus du référentiel thématique pour les utiliser comme clé de filtrage sur le dataset principal. Création d'un dataframe basé sur EdStatsSeries contenant uniquement les `Topic` séléctionnés précédemment via `isin()` à partie d'une white list.

```
display(df_series_filtered)
```

	Series Code	Topic	Indicator Name	Short definition	Long definition	Other notes	Source
0	BAR.NOED.1519.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15-19 with...	Percentage of female population age 15-19 with...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
1	BAR.NOED.1519.ZS	Attainment	Barro-Lee: Percentage of population age 15-19 ...	Percentage of population age 15-19 with no edu...	Percentage of population age 15-19 with no edu...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
2	BAR.NOED.15UP.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15+ with n...	Percentage of female population age 15+ with n...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
3	BAR.NOED.15UP.ZS	Attainment	Barro-Lee: Percentage of population age 15+ wi...	Percentage of population age 15+ with no educa...	Percentage of population age 15+ with no educa...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
4	BAR.NOED.2024.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 20-24 with...	Percentage of female population age 20-24 with...	NaN	Robert J. Barro and Jong-Wha Lee: http://www.b...
...	...	...	...	...	...	...	...
3552	UIS.thDur.4.A.GPV	Tertiary	Theoretical duration of post-secondary non-ter...	NaN	Number of grades (years) in post-secondary edu...	NaN	UNESCO Institute for Statistics
3553	UIS.TranRA.23.GPV.GPI	Secondary	Effective transition rate from primary to lowe...	NaN	The ratio of the female transition rate to the...	NaN	UNESCO Institute for Statistics
3578	UIS.UAPP.23	Secondary	Under-age enrolment ratio in secondary educati...	NaN	Percentage of the secondary school age populat...	NaN	UNESCO Institute for Statistics
3579	UIS.UAPP.23.F	Secondary	Under-age enrolment ratio in	NaN	Percentage of the female secondary	NaN	UNESCO Institute for Statistics

	Series Code	Topic	Indicator Name	Short definition	Long definition	Other notes	Source
			secondary educati...		school age ...		
3580	UIS.UAPP.23.M	Secondary	Under-age enrolment ratio in secondary educati...	NaN	Percentage of the male secondary school age po...	NaN	UNESCO Institute for Statistics

2227 rows × 7 columns

```
display(Markdown(f"Nombre de lignes dans `EdStatsSeries.csv` : {len(dataframes[4]['da
```

Nombre de lignes dans `EdStatsSeries.csv` : 3665, nombres de lignes restant aprés filtrage par `Topic` : 2227

```
display(Markdown(f"### Nombre d'indicateur restant {len(valid_series_codes)}"))
```

Nombre d'indicateur restant 2227

Création d'une liste de `Series Code` associé aux `Topic` séléctionnés.

```
display(valid_series_codes[:5])
```

```
['BAR.NOED.1519.FE.ZS',
 'BAR.NOED.1519.ZS',
 'BAR.NOED.15UP.FE.ZS',
 'BAR.NOED.15UP.ZS',
 'BAR.NOED.2024.FE.ZS']
```

5.2. Filtrer l'ensemble des jeux de données

```
df_data = dataframes[1]['data']
df_data_filtered_EdStatsCountry_Series = df_data[df_data['SeriesCode'].isin(valid_ser
display(df_data_filtered_EdStatsCountry_Series)
```

CountryCode	SeriesCode	DESCRIPTION

```
df_data = dataframes[2]['data']
df_data_filtered = df_data[df_data['Indicator Code'].isin(valid_series_codes)]
display(Markdown(f"Nombre de ligne avant filtrage : {len(dataframes[2]['data'])}"))
```

Nombre de ligne avant filtrage : 784310

```
dataframes[2]['data'] = df_data_filtered
display(dataframes[2]['data'])
```

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1975	1980	1985	1990
91625	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN
91626	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	NaN
91627	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	NaN
91628	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	NaN	NaN
91633	Afghanistan	AFG	Adjusted net enrolment rate, upper secondary, ...	UIS.NERA.3	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...
886922	Zimbabwe	ZWE	Youth illiterate population, 15-24 years, % fe...	UIS.LPP.AG15T24	NaN	NaN	NaN	NaN	NaN
886926	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, b...	SE.ADT.1524.LT.ZS	NaN	NaN	NaN	NaN	NaN
886927	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, f...	SE.ADT.1524.LT.FE.ZS	NaN	NaN	NaN	NaN	NaN

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1975	1980	1985	1990
886928	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, g...	SE.ADT.1524.LT.FM.ZS	NaN	NaN	NaN	NaN	NaN
886929	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, m...	SE.ADT.1524.LT.MA.ZS	NaN	NaN	NaN	NaN	NaN

470158 rows × 34 columns

```
display(Markdown(f"Nombre de lignes aprés filtrage : {len(dataframes[2]['data'])}"))
```

Nombre de lignes aprés filtrage : 470158

```
df_data = dataframes[3]['data']
df_data_filtered = df_data[df_data['SeriesCode'].isin(valid_series_codes)]
display(Markdown(f"Nombre de ligne avant filtrage : {len(dataframes[3]['data'])}"))
```

Nombre de ligne avant filtrage : 515752

```
dataframes[3]['data'] = df_data_filtered
display(dataframes[3]['data'])
```

	CountryCode	SeriesCode	Year	DESCRIPTION	Country Code
3	ABW	SE.SEC.ENRL.GC	YR2004	Country estimation.	ABW
6	ABW	SE.SEC.ENRL.VO.FE	YR2005	Country estimation.	ABW
7	ABW	SE.SEC.ENRL.GC	YR2003	Country estimation.	ABW
12	ABW	SE.SEC.ENRL.VO.FE.ZS	YR2002	Country estimation.	ABW
14	ABW	SE.SEC.ENRL.VO.FE.ZS	YR2007	Country estimation.	ABW
...	...	...	...	...	...
515701	ZWE	SE.TER.ENRR.MA	YR1992	Country Data	ZWE
515702	ZWE	SE.TER.GRAD.FE.ZS	YR1981	Country Data	ZWE
515733	ZWE	SE.SEC.ENRL.GC	YR1999	Country estimation.	ZWE
515734	ZWE	SE.SEC.ENRL.GC.FE	YR1998	UIS estimation.	ZWE
515735	ZWE	SE.SEC.ENRL.GC.FE.ZS	YR2000	Country estimation.	ZWE

218137 rows × 5 columns

```
display(Markdown(f"Nombre de lignes aprés filtrage : {len(dataframes[3]['data'])}"))
```

Nombre de lignes aprés filtrage : 218137

5.3. Filtrage temporel

Création d'une liste contenant les années non conservé via `np.range`. Cette liste ce compose de la concaténation des années passé plus les années futures.

```
past_years = np.arange(1970, 2010).astype(str).tolist()
future_years = np.arange(2028, 2101).astype(str).tolist()
columns_to_delete = past_years + future_years

display(columns_to_delete[:5])
```

```
['1970', '1971', '1972', '1973', '1974']
```

5.4. Filtrer le fichier Data

```
display(Markdown(f"### Dimensions du dataset avant filtrage temporel : {dataframes[2]
```

Dimensions du dataset avant filtrage temporel : (470158, 34)

```
dataframes[2]['data'].drop(columns=columns_to_delete, errors='ignore', inplace=True)
display(dataframes[2]['data'].head())
```

	Country Name	Country Code	Indicator Name	Indicator Code	2010	2011	2012	2013	2014
91625	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	47.436790	50.62723
91626	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	34.073261	37.64154
91627	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	0.567060	0.59837
91628	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	60.087059	62.90695
91633	Afghanistan	AFG	Adjusted net enrolment rate, upper secondary, ...	UIS.NERA.3	NaN	NaN	NaN	31.332621	32.41703

```
display(Markdown(f"### Dimensions du dataset aprés filtrage temporel : {dataframes[2]
```

Dimensions du dataset aprés filtrage temporel : (470158, 10)

Analyse de la disponibilité temporelle

Bien que notre périmètre d'étude cible initialement la plage 2010-2027, l'audit de complétude révèle une attrition massive des données sur la période récente.

Limiter l'analyse à 2010-2015

D'un point de vue statistique et métier, conserver les années au-delà de 2015 introduirait des risques majeurs:

1. **Absence de représentativité** : Un taux de complétude inférieur à 2 % signifie que moins d'une cinquantaine de points de données subsistent pour l'ensemble du globe. Une décision d'investissement ne peut reposer sur un échantillon aussi restreint.
2. **Biais de sélection** : Seuls quelques pays très spécifiques (souvent les plus développés ou ayant des programmes de collecte particuliers) renseignent ces années récentes. Analyser 2025 reviendrait à ignorer 99 % des marchés potentiels d'Academy.
3. **Nature des données futures** : Les colonnes 2020-2027 dans ce dataset sont essentiellement des projections théoriques. En l'absence de valeurs réelles saisies, elles n'offrent aucune plus-value pour un scoring de pays comparatif.

Conclusion de l'audit : Nous privilégions la qualité à la quantité. La fenêtre 2010-2015 constitue le segment le plus récent offrant une masse critique de données (complétude ~28 %) permettant d'établir un diagnostic international fiable et comparable.

6 : Analyse de la complétude (Data Fill Rate)

Cette section constitue le cœur de notre audit statistique. L'objectif est de quantifier la densité des données pour identifier les indicateurs présentant une masse critique suffisante pour un scoring international fiable.

Méthodologie appliquée :

1. **Développement d'un indicateur de densité :**
   - Création d'une fonction `calculate_data_fill_rate` permettant de mesurer la proportion de valeurs non-nulles (`.notnull()`) sur n'importe quel axe du DataFrame.
   - **Axe temporel (Années)** : Identification des années les mieux renseignées pour l'ensemble des thématiques.
   - **Axe thématique (Indicateurs)** : Évaluation de la régularité de mise à jour de chaque métrique sur la période 2010-2015.
2. **Mesure de la couverture géographique :**
   - Utilisation de la fonction `groupby('Indicator Name').count()` pour dénombrer, pour chaque indicateur, le nombre de pays ayant fourni au moins une valeur réelle.
   - **Scoring cumulé** : Création de la variable `Somme_Pays_Total` qui agrège la présence de données sur l'ensemble de la fenêtre temporelle pour classer les indicateurs par "richesse".
3. **Stratégie de sélection finale :**
   - **Arbitrage Quantité/Qualité** : Nous trions les résultats par ordre décroissant pour isoler le "Top 15" des indicateurs.
   - **Filtre Métier** : Parmi les plus riches, nous ne conservons que ceux répondant aux trois piliers d'Academy :
     - **Potentiel client** : Volume d'étudiants (Secondary/Tertiary).
     - **Faisabilité technique** : Accès au numérique (Internet Users).
     - **Besoin en soutien** : Performance éducative (Learning Outcomes).

6.1. Développement d'un indicateur de densité :

Pour évaluer la fiabilité de notre dataset, nous avons développé une fonction utilitaire permettant de mesurer la densité des données. Cette approche évite la répétition de code (principe DRY - Don't Repeat Yourself) et garantit une mesure homogène sur tous les axes du DataFrame.

Justification de la logique appliquée :

- `.notnull()` : Cette méthode crée un masque booléen identifiant chaque cellule contenant une information réelle. Les valeurs NaN (manquantes) sont ignorées.
- `.mean(axis=axis)` : En calculant la moyenne de ce masque booléen (True valant 1 et False valant 0), nous obtenons directement le taux de remplissage exprimé entre 0 et 1.
- Flexibilité de l'axe (`axis`) :
  - `axis=0` (par colonne) : Permet d'identifier les années les plus riches en données pour l'ensemble des pays
  - `axis=1` (par ligne) : Permet de calculer un score de fiabilité pour chaque indicateur spécifique, en mesurant sa régularité sur la plage temporelle choisie.

> **Note métier** : Cette fonction nous permet de ne retenir que les segments ayant une masse critique suffisante pour que les conclusions stratégiques d'Academy soient statistiquement significatives.

```
def calculate_data_fill_rate(df_analys, axis=0):
    return df_analys.notnull().mean(axis=axis)
```

1. **Fonctionnement technique : Le Slicing avec `.loc`**
   - `.loc` : C'est une méthode d'accès par étiquettes (labels).
   - `:` : Le premier argument (avant la virgule) signifie qu'on sélectionne toutes les lignes.
   - `'2010':'2015'` : Le deuxième argument définit la plage de colonnes. Grâce à l'opérateur `:`, Pandas récupère toutes les colonnes situées entre 2010 et 2015 inclus.

```
df_years_only = dataframes[2]['data'].loc[:, '2010':'2015']
display(df_years_only)
```

	2010	2011	2012	2013	2014	2015
91625	NaN	NaN	NaN	47.436790	50.627232	NaN
91626	NaN	NaN	NaN	34.073261	37.641541	NaN
91627	NaN	NaN	NaN	0.567060	0.598370	NaN
91628	NaN	NaN	NaN	60.087059	62.906952	NaN
91633	NaN	NaN	NaN	31.332621	32.417030	NaN
...	...	...	...	...	...	...
886922	NaN	43.61436	NaN	NaN	35.887100	NaN
886926	NaN	90.93070	NaN	NaN	90.428120	NaN
886927	NaN	92.12456	NaN	NaN	93.188350	NaN
886928	NaN	1.02828	NaN	NaN	1.063890	NaN
886929	NaN	89.59058	NaN	NaN	87.591860	NaN

470158 rows × 6 columns

> **Fonctionnement technique** :
>
> - `calculate_data_fill_rate(..., axis=0)` : En passant l'argument axis=0, on indiques à la fonction de calculer la moyenne verticalement (colonne par colonne).
> - `.to_frame(name='...')` : Par défaut, le résultat est une Series Pandas (une simple liste indexée). Cette méthode la convertit en un DataFrame, ce qui facilite la lecture et l'exportation future du rapport.

```
data_fill_rate_per_year = calculate_data_fill_rate(df_years_only, axis=0)
display(data_fill_rate_per_year.to_frame(name='Ratio de complétude'))
```

	Ratio de complétude
2010	0.302315
2011	0.096706
2012	0.101542
2013	0.085497
2014	0.074739
2015	0.151392

> **Fonctionnement technique** :

- `calculate_data_fill_rate(..., axis=1)` : En passant l'argument axis=0, on indiques à la fonction de calculer la moyenne verticalement (ligne par ligne).

```
data_fill_rate_per_indicator = calculate_data_fill_rate(df_years_only, axis=1)
display(data_fill_rate_per_indicator.to_frame(name='Ratio de complétude'))
```

	Ratio de complétude
91625	0.333333
91626	0.333333
91627	0.333333
91628	0.333333
91633	0.333333
...	...
886922	0.333333
886926	0.333333
886927	0.333333
886928	0.333333
886929	0.333333

470158 rows × 1 columns

6.2. Stratégie de sélection finale

Fonctionnement technique :

Le groupby est une opération en trois étapes souvent appelée **Split-Apply-Combine**.

- **Split** : Pandas rassemble toutes les lignes qui ont le même Indicator Name (par exemple, toutes les lignes "Internet users" de tous les pays).
- **Apply** : La fonction `.count()` est appliquée à chaque groupe.
  - Note importante : `.count()` ne compte que les valeurs non-nulles. Si un pays n'a pas de donnée pour 2010, il n'est pas compté.
- **Combine** : Pandas rassemble les résultats dans un nouveau tableau où chaque ligne est un indicateur unique, et chaque colonne contient le nombre de pays l'ayant renseigné.

Mesure de la couverture géographique : On ne regarde plus si une cellule est vide, on regarde si l'indicateur est global. Un indicateur présent dans 200 pays a beaucoup plus de valeur qu'un indicateur présent dans seulement 5 pays.

> **Tri stratégique** : Le `sort_values` permet d'isoler immédiatement les "indicateurs stars" (comme Internet users ou Secondary enrolment) qui seront les piliers de la stratégie d'Academy.

```
df_density = dataframes[2]['data'][['Indicator Name', '2010', '2011', '2012', '2013',
indicators_per_countries = df_density.groupby('Indicator Name').count()
indicators_per_countries['Somme_Pays_Total'] = indicators_per_countries.sum(axis=1)
sort_indicators = indicators_per_countries.sort_values(by='Somme_Pays_Total', ascendi
with pd.option_context(
    'display.max_columns', None,
    'display.max_rows', None
):
    display(sort_indicators.head(70))
```

Indicator Name	2010	2011	2012	2013	2014	2015	Somme_Pays_Total
Official entrance age to lower secondary education (years)	202	201	201	202	202	202	1210
Theoretical duration of secondary education (years)	202	201	201	202	202	202	1210
Theoretical duration of upper secondary education (years)	202	201	201	202	202	202	1210
Internet users (per 100 people)	201	203	201	201	201	201	1208
Enrolment in secondary general, both sexes (number)	156	162	161	155	154	139	927
Percentage of students in secondary general education who are female (%)	156	162	161	154	154	139	926
Enrolment in secondary general, female (number)	156	162	161	154	154	139	926
Gross enrolment ratio, lower secondary, both sexes (%)	151	159	156	148	147	129	890
Gross enrolment ratio, lower secondary, female (%)	151	157	155	147	146	129	885
Gross enrolment ratio, lower secondary, male (%)	151	157	155	147	146	129	885
Enrolment in secondary education, both sexes (number)	150	155	148	140	139	122	854
Percentage of students in secondary education who are female (%)	150	154	147	137	137	121	846
Enrolment in secondary education, female (number)	150	154	147	137	137	121	846
Gross enrolment ratio, upper secondary, both sexes (%)	144	149	144	136	133	114	820
Gross enrolment ratio, secondary, both sexes (%)	145	149	142	134	133	117	820
Gross enrolment ratio, secondary, male (%)	145	148	141	131	131	116	812
Gross enrolment ratio, secondary, gender parity index (GPI)	145	148	141	131	131	116	812
Gross enrolment ratio, secondary, female (%)	145	148	141	131	131	116	812
Gross enrolment ratio, upper secondary, male (%)	144	147	143	134	131	113	812

Indicator Name	2010	2011	2012	2013	2014	2015	Somme_Pays_Total
Enrolment in lower secondary general, female (number)	161	166	167	157	135	8	794
Enrolment in lower secondary general, both sexes (number)	161	166	167	157	135	8	794
Percentage of students in lower secondary general education who are female (%)	161	166	167	157	135	8	794
Enrolment in tertiary education, all programmes, both sexes (number)	140	142	141	131	124	109	787
Gross enrolment ratio, primary and secondary, gender parity index (GPI)	140	145	138	125	127	111	786
Percentage of students in tertiary education who are female (%)	138	138	138	127	121	106	768
Percentage of students in upper secondary general education who are female (%)	157	161	159	153	130	8	768
Enrolment in upper secondary general, female (number)	157	161	159	153	130	8	768
Enrolment in tertiary education, all programmes, female (number)	138	138	138	127	121	106	768
Enrolment in upper secondary general, both sexes (number)	157	161	159	153	130	8	768
Percentage of enrolment in secondary education in private institutions (%)	129	134	130	130	130	114	767
Enrolment in lower secondary education, both sexes (number)	154	162	157	148	130	8	759
Enrolment in lower secondary education, female (number)	154	160	156	147	129	8	754
Percentage of students in lower secondary education who are female (%)	154	160	156	147	129	8	754
Percentage of students in lower secondary education enrolled in general programmes, both sexes (%)	151	160	157	147	129	8	752
Percentage of female students in lower secondary education enrolled in general programmes, female (%)	151	159	156	147	129	8	750
Percentage of male students in lower secondary education enrolled	151	159	156	147	129	8	750

Indicator Name	2010	2011	2012	2013	2014	2015	Somme_Pays_Total
in general programmes, male (%)							
Gross enrolment ratio, tertiary, both sexes (%)	133	138	136	125	119	99	750
Enrolment in secondary vocational, both sexes (number)	127	129	132	124	122	107	741
Lower secondary completion rate, both sexes (%)	123	127	125	127	126	109	737
Percentage of students in secondary education enrolled in vocational programmes, both sexes (%)	126	128	131	123	120	107	735
Gross enrolment ratio, tertiary, gender parity index (GPI)	131	134	133	122	116	97	733
Gross enrolment ratio, tertiary, female (%)	131	134	133	122	116	97	733
Gross enrolment ratio, tertiary, male (%)	131	134	133	122	116	97	733
Enrolment in secondary vocational, female (number)	126	127	130	123	121	105	732
Percentage of male students in secondary education enrolled in vocational programmes, male (%)	126	127	130	121	119	106	729
Lower secondary completion rate, female (%)	121	124	123	126	126	108	728
Lower secondary completion rate, male (%)	121	124	123	126	126	108	728
Enrolment in Grade 1 of lower secondary general education, both sexes (number)	149	154	147	140	129	8	727
Percentage of female students in secondary education enrolled in vocational programmes, female (%)	125	126	129	121	119	105	725
Enrolment in Grade 1 of lower secondary general education, female (number)	147	151	147	140	129	8	722
Percentage of students in secondary vocational education who are female (%)	122	124	128	122	119	103	718
Enrolment in Grade 2 of lower secondary general education, both sexes (number)	147	151	145	139	128	8	718

Indicator Name	2010	2011	2012	2013	2014	2015	Somme_Pays_Total
Enrolment in upper secondary education, both sexes (number)	149	154	151	140	117	7	718
Enrolment in Grade 2 of lower secondary general education, female (number)	146	149	145	139	128	8	715
Enrolment in upper secondary education, female (number)	149	152	150	140	114	7	712
Percentage of students in upper secondary education who are female (%)	149	152	150	139	114	7	711
Gross enrolment ratio, lower secondary, gender parity index (GPI)	146	153	147	139	119	7	711
Enrolment in lower secondary education, public institutions, both sexes (number)	144	148	142	140	120	7	701
Gross enrolment ratio, primary and lower secondary, both sexes (%)	141	150	143	133	116	7	690
School life expectancy, primary and lower secondary, both sexes (years)	141	150	143	133	116	7	690
Percentage of students in upper secondary education enrolled in general programmes, both sexes (%)	142	146	143	136	112	7	686
Percentage of students in secondary education enrolled in general programmes, both sexes (%)	143	147	141	134	113	7	685
Percentage of male students in upper secondary education enrolled in general programmes, male (%)	142	145	142	135	110	7	681
Percentage of female students in upper secondary education enrolled in general programmes, female (%)	142	145	142	135	110	7	681
Percentage of female students in secondary education enrolled in general programmes, female (%)	143	146	140	133	111	7	680
Percentage of male students in secondary education enrolled in general programmes, male (%)	143	146	140	133	111	7	680

Indicator Name	2010	2011	2012	2013	2014	2015	Somme_Pays_Total
School life expectancy, secondary, both sexes (years)	145	150	140	131	108	6	680
School life expectancy, primary and lower secondary, female (years)	139	147	141	130	114	7	678
School life expectancy, primary and lower secondary, male (years)	139	147	141	130	114	7	678
Gross enrolment ratio, primary and lower secondary, female (%)	139	147	141	130	114	7	678

6.3. Sélection finale des indicateurs clés

Cette liste constitue la variable selection_indicateurs_finale demandée par l'exercice. Elle équilibre la richesse des données (complétude) et la pertinence stratégique.

1. **Metriques coeur (Indispensables)** : Ces indicateurs mesurent directement la taille du marché et la faisabilité technique de l'offre en ligne d'Academy.
   - **Internet users (per 100 people)** : Indispensable pour valider la faisabilité du e-learning.
   - **Enrolment in secondary education, both sexes (number)** : Mesure la taille brute du marché "Lycée".
   - **Enrolment in lower secondary education (number)** : Volume du vivier entrant (Collège), remplace la donnée démographique brute.
   - **Enrolment in tertiary education, all programmes, both sexes (number)** : Mesure la taille brute du marché "Université".
   - **Gross enrolment ratio, secondary, both sexes (%)** : Indique le taux de scolarisation (pénétration du système éducatif).
   - **Gross enrolment ratio, tertiary, both sexes (%)** : Indique l'accès à l'enseignement supérieur.
   - **Percentage of students in secondary education enrolled in vocational programmes, both sexes (%)** : Dans les pays où ce taux est faible, cela signifie que la grande majorité des élèves sont en filière générale et visent le baccalauréat/université. Le besoin d'Academy y est donc maximal.
2. **Metriques contextuels (Utiles)** : Ces indicateurs permettent d'affiner le "scoring" en mesurant le niveau de développement éducatif et le besoin potentiel.
   - **Literacy rate, population 25-64 years (%)** : Niveau de compétences du socle parental et adulte (décisionnaires d'achat).
   - **School life expectancy, secondary (years)** : Mesure l'investissement temporel dans l'éducation, remplace les données de dépenses publiques.
   - **Percentage of enrolment in private institutions (%)** : Mesure l'appétence du marché pour les services éducatifs payants.

- **Theoretical duration of secondary education (years)** : Structure temporelle du cycle d'étude national.
- **School life expectancy, primary and lower secondary (years)** : Indicateur de la solidité de la base éducative.
- **Lower secondary completion rate, both sexes (%)** : Mesure le flux d'étudiants arrivant vers le Lycée.
- **Barro-Lee: Average years of total secondary education, ages 15+, total** : Donne une vision du stock de compétences "Lycée" déjà présent.
- **Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary** : Précise le niveau de diplôme moyen de la cible.

7. Construction du Dataset Décisionnel (Pivotement & Agrégation)

L'objectif de cette phase est de restructurer nos données pour obtenir une **"Source Unique de Vérité"** par pays. Nous passons d'un format "long" (plusieurs lignes d'indicateurs et plusieurs colonnes d'années par pays) à un format "large", où chaque pays est décrit par une ligne unique regroupant l'ensemble de nos variables stratégiques.

Méthodologie appliquée :

1. Filtrage Final du Périmètre :

- **Indicateurs** : Utilisation de la liste `final_indicators` regroupant les 15 indicateurs clés retenus pour leur pertinence métier (Lycée, Université, IT).
- **Années** : Focalisation sur la fenêtre **2010-2015**, identifiée précédemment comme le segment le plus dense et le plus fiable en données exploitables.

2. Stratégie d'Agrégation Temporelle :

- Puisque nous disposons de données réparties sur 6 ans, il est nécessaire de résumer cette période en une statistique unique par couple (Pays, Indicateur).
- **Choix de la Moyenne (`mean`)** : Nous optons pour la moyenne arithmétique afin de lisser les éventuelles variations annuelles. Cela permet d'obtenir une tendance stable du niveau d'éducation et d'équipement sur la période choisie.

3. Pivotement des Données (`pivot_table`) :

- **Restructuration** : Le DataFrame est pivoté pour que chaque `Indicator Name` devienne une colonne distincte.
- **Unicité** : Chaque ligne représentera désormais un **pays unique**, facilitant ainsi le futur calcul de scoring et la comparaison directe entre les marchés potentiels.

```
final_indicators = [
    'Internet users (per 100 people)',
    'Enrolment in secondary education, both sexes (number)',
    'Enrolment in tertiary education, all programmes, both sexes (number)',
    'Gross enrolment ratio, secondary, both sexes (%)',
    'Gross enrolment ratio, tertiary, both sexes (%)',
    'Enrolment in lower secondary education, both sexes (number)',
    'Percentage of students in secondary education enrolled in vocational programmes,
    'Literacy rate, population 25-64 years, both sexes (%)',
    'School life expectancy, secondary, both sexes (years)',
    'Percentage of enrolment in secondary education in private institutions (%)',
    'Lower secondary completion rate, both sexes (%)',
    'Theoretical duration of secondary education (years)',
    'School life expectancy, primary and lower secondary, both sexes (years)',
    'Barro-Lee: Average years of secondary schooling, age 15+, total',
    'Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed S
]
display(final_indicators)
```

```
['Internet users (per 100 people)',
 'Enrolment in secondary education, both sexes (number)',
 'Enrolment in tertiary education, all programmes, both sexes (number)',
 'Gross enrolment ratio, secondary, both sexes (%)',
 'Gross enrolment ratio, tertiary, both sexes (%)',
 'Enrolment in lower secondary education, both sexes (number)',
 'Percentage of students in secondary education enrolled in vocational programmes, bo
th sexes (%)',
 'Literacy rate, population 25-64 years, both sexes (%)',
 'School life expectancy, secondary, both sexes (years)',
 'Percentage of enrolment in secondary education in private institutions (%)',
 'Lower secondary completion rate, both sexes (%)',
 'Theoretical duration of secondary education (years)',
 'School life expectancy, primary and lower secondary, both sexes (years)',
 'Barro-Lee: Average years of secondary schooling, age 15+, total',
 'Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Sec
ondary']
```

```
# Filtrage du dataframe final pour ne garder que ces 15 indicateurs
df_final_academy = dataframes[2]['data'][dataframes[2]['data']['Indicator Name'].isin
with pd.option_context(
    'display.float_format', '{:.2f}'.format,
    'display.max_columns', None,
    'display.max_rows', None
):
    display(df_final_academy)
    print(f"Nombre d'indicateurs uniques trouvés : {df_final_academy['Indicator Name']
```

```
Nombre d'indicateurs uniques trouvés : 15
```

7.2. Stratégie d'Agrégation Temporelle :

Avant de pivoter les données, nous devons définir une statistique capable de résumer la période 2010-2015 pour chaque couple (Pays, Indicateur).

Justification du choix de la Moyenne (mean) :

- **Lissage des données** : La moyenne arithmétique permet de compenser les éventuelles irrégularités de collecte annuelle.
- **Stabilité** : Elle offre une vision plus robuste du niveau de développement éducatif et numérique d'un pays sur le moyen terme.
- **Fiabilité** : Notre audit précédent ayant validé la complétude de ce segment (~28%), le calcul de la moyenne repose sur une base statistique exploitable.

> **Fonctionnement du code :**
>
> 1. `groupby` : Nous regroupons les données par pays et par indicateur pour isoler les séries temporelles correspondantes.
> 2. `.mean()` : Nous appliquons la moyenne sur les colonnes définies dans analysis_years. Les valeurs manquantes (NaN) sont automatiquement ignorées par Pandas dans ce calcul.
> 3. `Period_Average` : Cette nouvelle colonne devient notre métrique de référence (Source of Truth) pour la suite de l'analyse et le futur pivotement.

```
analysis_years = ['2010', '2011', '2012', '2013', '2014', '2015']

temporal_aggregation_df = df_final_academy.groupby(['Country Name', 'Country Code', '
temporal_aggregation_df['Period_Average'] = temporal_aggregation_df.mean(axis=1)

display(temporal_aggregation_df.head(15))
```

Country Name	Country Code	Indicator Name	2010	2011	2012	2013
Afghanistan	AFG	Barro-Lee: Average years of secondary schooling, age 15+, total	1.000000e+00	NaN	NaN	NaN
		Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	8.650000e+00	NaN	NaN	NaN
		Enrolment in lower secondary education, both sexes (number)	1.476813e+06	1.465558e+06	1.534469e+06	1.569153e+06
		Enrolment in secondary education, both sexes (number)	2.044157e+06	2.208963e+06	2.415884e+06	2.538420e+06
		Enrolment in tertiary education, all programmes, both sexes (number)	NaN	9.750400e+04	NaN	NaN
		Gross enrolment ratio, secondary, both sexes (%)	5.324683e+01	5.461618e+01	5.667734e+01	5.668866e+01
		Gross enrolment ratio, tertiary, both sexes (%)	NaN	3.755980e+00	NaN	NaN
		Internet users (per 100 people)	4.000000e+00	5.000000e+00	5.454545e+00	5.900000e+00

Country Name	Country Code	Indicator Name	2010	2011	2012	2013
		Literacy rate, population 25-64 years, both sexes (%)	NaN	2.315362e+01	NaN	NaN
		Lower secondary completion rate, both sexes (%)	NaN	NaN	NaN	NaN
		Percentage of enrolment in secondary education in private institutions (%)	NaN	1.273540e+00	1.947610e+00	NaN
		Percentage of students in secondary education enrolled in vocational programmes, both sexes (%)	NaN	8.187100e-01	9.693800e-01	1.162930e+00
		School life expectancy, primary and lower secondary, both sexes (years)	8.467990e+00	8.185760e+00	8.550590e+00	8.648100e+00
		School life expectancy, secondary, both sexes (years)	3.194810e+00	3.276970e+00	3.400640e+00	3.478320e+00
		Theoretical duration of secondary education (years)	6.000000e+00	6.000000e+00	6.000000e+00	6.000000e+00

7.3. Pivotement des Données (`pivot_table`) :

Cette étape marque la transition finale vers une structure de données prête pour l'analyse comparative. Nous transformons nos indicateurs thématiques en variables explicatives pour chaque pays.

Justification technique et metier :

- **Restructuration dimensionnelle** : L'utilisation de `pivot_table()` permet de basculer les noms d'indicateurs de la dimension verticale (lignes) vers la dimension horizontale (colonnes).
- **Unicité de l'observation** : Chaque ligne correspond désormais à une seule entité géographique (un pays unique), ce qui est le format standard pour appliquer un algorithme de scoring ou de machine learning.
- **Standardisation de l'accès** : En supprimant le nom de l'index des colonnes (`columns.name = None`) et en réinitialisant l'index (`reset_index`), nous transformons les métadonnées (`Country Name` , `Country Code`) en colonnes classiques, facilitant les futures manipulations de filtrage et d'exportation.

> **Fonctionnement du code** :
>
> 1. `pivot_table` : Nous utilisons la colonne Period_Average calculée précédemment comme valeur centrale.
> 2. `option_context` : Ce bloc permet de forcer un rendu exhaustif dans le Notebook sans modifier les réglages globaux de ta session.
>
> - `max_columns : None` : Affiche les 15 indicateurs sans troncature centrale.
> - `max_rows : None` : Affiche l'intégralité des 214 pays identifiés comme valides lors du nettoyage.

```
final_decision_dataset = temporal_aggregation_df.reset_index().pivot_table(
    index=['Country Name', 'Country Code'],
    columns='Indicator Name',
    values='Period_Average'
)

final_decision_dataset.columns.name = None
final_academy_dataset = final_decision_dataset.reset_index()

with pd.option_context(
    'display.float_format', '{:.2f}'.format,
    'display.max_columns', None,
    'display.max_rows', None
):
    display(final_academy_dataset)
```

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
0	Afghanistan	AFG	1.00	8.65	1535991.60	2418162.33	180189.00	
1	Albania	ALB	3.40	42.90	198123.80	342505.50	154236.17	
2	Algeria	DZA	2.12	17.08	3274861.50	4594369.50	1221772.67	
3	Andorra	AND	NaN	NaN	2974.80	4229.83	507.00	
4	Angola	AGO	NaN	NaN	574204.00	867658.00	194171.33	
5	Antigua and Barbuda	ATG	NaN	NaN	5642.00	8278.60	1343.33	
6	Argentina	ARG	2.66	31.07	2666247.50	4339148.00	2709143.40	
7	Armenia	ARM	5.29	57.12	167930.40	259772.40	124134.50	
8	Aruba	ABW	NaN	NaN	3457.67	7699.00	1839.50	
9	Australia	AUS	4.59	38.49	1287899.20	2348681.60	1361789.40	
10	Austria	AUT	5.26	40.81	345387.77	712017.22	393076.12	
11	Azerbaijan	AZE	NaN	NaN	615748.00	NaN	188960.17	
12	Bahamas, The	BHS	NaN	NaN	17698.00	34406.00	NaN	
13	Bahrain	BHR	2.69	32.11	43915.80	86054.83	38956.20	
14	Bangladesh	BGD	2.40	24.97	6844861.12	12589004.20	2037936.67	
15	Barbados	BRB	3.49	21.76	11749.67	19932.00	12826.50	
16	Belarus	BLR	NaN	NaN	454718.60	688617.00	549757.17	
17	Belgium	BEL	4.23	33.24	341635.60	1006150.67	479097.17	
18	Belize	BLZ	3.41	30.33	27031.20	35585.67	7908.60	
19	Benin	BEN	1.74	17.77	615581.33	863316.75	123328.25	
20	Bermuda	BMU	NaN	NaN	2011.80	4211.67	1191.33	
21	Bhutan	BTN	NaN	NaN	50293.80	66375.60	7076.25	
22	Bolivia	BOL	2.20	17.95	429679.75	1099105.83	NaN	
23	Bosnia and Herzegovina	BIH	NaN	NaN	154781.60	306145.67	108801.50	
24	Botswana	BWA	3.18	29.03	120572.00	NaN	49999.33	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
25	Brazil	BRA	2.27	26.37	14220462.50	23780051.00	7437028.17	
26	Brunei Darussalam	BRN	3.67	30.69	15133.20	49838.67	8615.50	
27	Bulgaria	BGR	4.43	46.80	226779.00	516500.33	283925.33	
28	Burkina Faso	BFA	NaN	NaN	562243.80	731395.67	63833.50	
29	Burundi	BDI	0.53	4.97	343669.20	479524.00	38148.40	
30	Cabo Verde	CPV	NaN	NaN	37252.80	61105.33	12119.33	
31	Cambodia	KHM	0.97	4.51	564186.80	NaN	211917.33	
32	Cameroon	CMR	1.80	15.28	1240034.75	1841821.40	299479.67	
33	Canada	CAN	5.11	31.79	981078.00	2656886.50	NaN	
34	Cayman Islands	CYM	NaN	NaN	1805.67	3311.67	NaN	
35	Central African Republic	CAF	1.11	9.54	99471.00	125962.00	12323.00	
36	Chad	TCD	NaN	NaN	315244.67	448321.67	29647.33	
37	Chile	CHL	3.81	38.13	518942.40	1521480.00	1128151.67	
38	China	CHN	2.30	22.85	50311447.20	93469693.33	35720659.00	
39	Colombia	COL	3.48	24.99	3599993.80	4940986.83	2017623.50	
40	Comoros	COM	NaN	NaN	39178.00	68999.00	5647.60	
41	Congo, Dem. Rep.	COD	1.02	12.56	1762853.20	3909103.00	480638.33	
42	Congo, Rep.	COG	2.12	6.64	243984.00	339250.00	36756.00	
43	Costa Rica	CRI	2.08	18.86	294182.20	438111.00	207589.40	
44	Cote d'Ivoire	CIV	1.29	8.09	1047154.00	1502854.50	149809.20	
45	Croatia	HRV	4.13	49.85	198183.50	377156.50	158968.00	
46	Cuba	CUB	4.10	29.48	417204.20	805659.50	484217.00	
47	Curacao	CUW	NaN	NaN	4238.00	11219.00	2196.00	
48	Cyprus	CYP	4.27	35.05	29350.80	60824.17	33154.67	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
49	Czech Republic	CZE	3.79	68.77	368836.60	795409.83	427556.00	
50	Denmark	DNK	4.91	38.88	245612.00	535583.83	280129.83	
51	Djibouti	DJI	NaN	NaN	36586.80	56247.60	3965.00	
52	Dominica	DMA	NaN	NaN	4223.50	6278.00	NaN	
53	Dominican Republic	DOM	2.73	25.23	344525.20	914859.50	460611.33	
54	Ecuador	ECU	2.25	25.34	922826.00	1770602.00	579413.00	
55	Egypt, Arab Rep.	EGY	2.94	26.38	4659497.40	7766372.60	2513976.33	
56	El Salvador	SLV	1.56	22.70	393192.80	608001.50	168666.33	
57	Equatorial Guinea	GNQ	NaN	NaN	NaN	NaN	NaN	
58	Eritrea	ERI	NaN	NaN	157420.75	259120.33	12296.50	
59	Estonia	EST	5.14	46.53	39243.50	84642.33	64287.17	
60	Ethiopia	ETH	NaN	NaN	3929530.25	4676427.75	665100.00	
61	Faroe Islands	FRO	NaN	NaN	NaN	NaN	NaN	
62	Fiji	FJI	3.09	36.33	63288.67	99083.50	NaN	
63	Finland	FIN	5.42	38.88	184689.80	480516.67	306396.83	
64	France	FRA	5.11	38.22	3299885.20	5908553.60	2305573.20	
65	French Polynesia	PYF	NaN	NaN	NaN	NaN	NaN	
66	Gabon	GAB	3.26	23.18	NaN	NaN	NaN	
67	Gambia, The	GMB	1.51	4.63	81152.80	124397.00	4557.00	
68	Georgia	GEO	NaN	NaN	153340.40	284069.67	112821.83	
69	Germany	DEU	6.84	54.75	4760380.40	7364732.67	2889999.08	
70	Ghana	GHA	2.87	18.50	1446225.00	2286793.20	351140.00	
71	Greece	GRC	3.61	29.05	332255.50	692902.20	660599.20	
72	Greenland	GRL	NaN	NaN	NaN	NaN	NaN	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
73	Grenada	GRD	NaN	NaN	6522.00	10143.00	9236.00	
74	Guam	GUM	NaN	NaN	NaN	NaN	NaN	
75	Guatemala	GTM	0.95	10.23	750378.80	1146957.33	330197.50	
76	Guinea	GIN	NaN	NaN	464452.33	671110.00	106058.00	
77	Guinea-Bissau	GNB	NaN	NaN	NaN	NaN	NaN	
78	Guyana	GUY	3.50	33.01	56172.33	84383.33	8387.67	
79	Haiti	HTI	1.83	23.10	NaN	NaN	NaN	
80	Honduras	HND	1.59	16.13	402493.20	646363.33	181976.00	
81	Hong Kong SAR, China	HKG	5.10	43.74	213868.40	455174.00	284839.09	
82	Hungary	HUN	3.51	52.92	397951.80	871173.33	357976.33	
83	Iceland	ISL	4.27	25.21	13148.67	36301.25	18773.00	
84	India	IND	2.67	25.03	62163904.00	119824084.00	27758084.00	
85	Indonesia	IDN	2.30	22.09	12224952.60	21810889.00	5765680.67	
86	Iran, Islamic Rep.	IRN	3.88	30.54	2825571.20	6512998.00	4361448.17	
87	Iraq	IRQ	2.43	17.40	NaN	NaN	NaN	
88	Ireland	IRL	4.04	24.69	187080.50	342225.20	200158.17	
89	Israel	ISR	4.84	39.07	383938.80	744294.83	371634.33	
90	Italy	ITA	4.58	34.54	1792885.50	4604448.00	1904571.33	
91	Jamaica	JAM	3.93	34.23	147347.25	237750.20	73850.80	
92	Japan	JPN	4.69	40.98	3613986.25	7275575.00	3865341.00	
93	Jordan	JOR	3.77	27.09	514553.67	726845.80	279688.50	
94	Kazakhstan	KAZ	6.61	66.25	1205875.67	1716655.17	757140.00	
95	Kenya	KEN	1.47	13.30	2005473.50	NaN	NaN	
96	Kiribati	KIR	NaN	NaN	6790.00	NaN	NaN	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
97	Korea, Dem. People's Rep.	PRK	NaN	NaN	NaN	2148364.00	582887.00	
98	Korea, Rep.	KOR	4.85	35.46	1892237.25	3721114.00	3318988.17	
99	Kuwait	KWT	3.04	18.70	164591.33	275822.33	71786.00	
100	Kyrgyz Republic	KGZ	6.26	65.02	488032.40	663278.17	267906.83	
101	Lao PDR	LAO	1.47	6.04	369964.40	538475.00	128275.00	
102	Latvia	LVA	4.98	41.60	58013.40	129151.33	97248.33	
103	Lebanon	LBN	NaN	NaN	216666.75	384111.67	217893.83	
104	Lesotho	LSO	0.98	13.18	94681.80	130990.50	24375.00	
105	Liberia	LBR	1.21	12.49	138926.00	229110.67	38676.50	
106	Libya	LBY	2.76	15.99	NaN	NaN	NaN	
107	Liechtenstein	LIE	NaN	NaN	1715.50	3317.00	862.20	
108	Lithuania	LTU	4.90	51.25	213475.40	301289.67	168711.50	
109	Luxembourg	LUX	4.48	27.58	21343.25	44615.60	5730.50	
110	Macao SAR, China	MAC	3.12	32.11	17842.40	34539.17	28985.83	
111	Macedonia, FYR	MKD	NaN	NaN	96619.50	179997.80	61975.80	
112	Madagascar	MDG	NaN	NaN	1110275.50	1404232.33	92061.60	
113	Malawi	MWI	0.65	7.92	663356.60	833529.50	11249.50	
114	Malaysia	MYS	4.58	39.81	1498494.00	2796833.50	994819.00	
115	Maldives	MDV	2.10	11.38	21440.20	NaN	6089.00	
116	Mali	MLI	0.59	3.86	587795.80	873671.00	88706.33	
117	Malta	MLT	4.23	16.42	18076.80	31968.50	12155.67	
118	Marshall Islands	MHL	NaN	NaN	2872.50	5454.00	1330.00	
119	Mauritania	MRT	0.86	8.21	105284.60	153991.83	17721.60	
120	Mauritius	MUS	3.81	44.52	60386.40	128696.17	38241.17	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
121	Mexico	MEX	3.18	19.41	7883169.20	12223560.00	3141924.60	
122	Micronesia, Fed. Sts.	FSM	NaN	NaN	4453.00	NaN	NaN	
123	Moldova	MDA	6.02	54.27	184324.60	268434.00	122020.67	
124	Monaco	MCO	NaN	NaN	1713.00	3084.50	NaN	
125	Mongolia	MNG	5.21	45.61	171652.00	278972.00	173704.00	
126	Montenegro	MNE	NaN	NaN	33063.25	64325.00	23786.00	
127	Morocco	MAR	1.86	12.13	1549947.40	2475437.33	655504.17	
128	Mozambique	MOZ	0.33	3.38	595982.40	870694.00	135044.00	
129	Myanmar	MMR	1.37	9.51	2340715.00	3021857.50	646908.00	
130	Namibia	NAM	1.34	16.15	147262.00	NaN	NaN	
131	Nepal	NPL	1.33	12.59	1767314.17	3005349.67	428669.00	
132	Netherlands	NLD	4.61	38.39	800251.80	1553925.33	766799.50	
133	New Caledonia	NCL	NaN	NaN	NaN	NaN	NaN	
134	New Zealand	NZL	3.60	15.53	245530.80	498941.92	262596.53	
135	Nicaragua	NIC	2.02	17.29	319539.00	465201.00	NaN	
136	Niger	NER	0.42	3.39	331702.60	431228.00	19062.67	
137	Nigeria	NGA	NaN	NaN	5010227.00	10348244.00	1453978.00	
138	Norway	NOR	4.60	40.30	191077.20	437254.67	246754.50	
139	Oman	OMN	NaN	NaN	183823.50	295213.50	103527.20	
140	Pakistan	PAK	2.16	19.13	5935285.60	10687500.17	1821696.40	
141	Palau	PLW	NaN	NaN	504.50	1638.00	863.00	
142	Panama	PAN	3.27	26.38	186643.00	308245.00	134300.25	
143	Papua New Guinea	PNG	0.66	6.28	242768.00	378365.00	NaN	
144	Paraguay	PRY	2.22	20.81	338460.00	590534.33	225211.00	
145	Peru	PER	3.08	37.30	1765186.40	2673529.33	1150620.00	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
146	Philippines	PHL	2.50	23.84	5649790.00	7220389.00	3130088.40	
147	Poland	POL	3.32	58.39	1252858.75	2719600.60	1980321.20	
148	Portugal	PRT	2.35	15.46	385976.00	754440.00	373479.17	
149	Puerto Rico	PRI	NaN	NaN	146726.63	273548.70	247247.60	
150	Qatar	QAT	2.83	23.57	41156.00	80259.67	20081.17	
151	Romania	ROU	3.76	51.31	832536.40	1692514.00	719202.33	
152	Russian Federation	RUS	4.71	23.80	6164632.50	9181892.00	7550405.80	
153	Rwanda	RWA	0.68	6.16	344271.60	530601.67	73835.50	
154	Samoa	WSM	NaN	NaN	9343.00	25903.60	NaN	
155	San Marino	SMR	NaN	NaN	946.00	2369.67	913.33	
156	Sao Tome and Principe	STP	NaN	NaN	12143.00	15611.50	1550.75	
157	Saudi Arabia	SAU	3.16	29.11	1736739.00	3409842.00	1251993.83	
158	Senegal	SEN	0.59	2.19	NaN	898552.67	127124.67	
159	Serbia	SRB	4.35	48.71	286367.80	565279.67	234968.50	
160	Seychelles	SYC	NaN	NaN	4278.00	7412.17	408.00	
161	Sierra Leone	SLE	1.49	7.66	265752.00	405039.75	NaN	
162	Singapore	SGP	4.46	30.00	NaN	NaN	237307.75	
163	Sint Maarten (Dutch part)	SXM	NaN	NaN	1376.50	2847.00	182.33	
164	Slovak Republic	SVK	4.24	61.79	267375.00	498402.33	217891.00	
165	Slovenia	SVN	4.84	56.12	54288.20	139635.60	102867.60	
166	Solomon Islands	SLB	NaN	NaN	28070.40	40496.67	NaN	
167	Somalia	SOM	NaN	NaN	NaN	NaN	NaN	
168	South Africa	ZAF	3.38	53.90	2027199.00	4877621.50	1019952.67	
169	South Sudan	SSD	NaN	NaN	89615.00	149067.00	NaN	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
170	Spain	ESP	3.97	20.27	1872011.60	3271177.50	1951797.17	
171	Sri Lanka	LKA	3.73	17.89	1319451.60	2573617.25	280466.50	
172	St. Kitts and Nevis	KNA	NaN	NaN	2703.60	4293.17	3459.50	
173	St. Lucia	LCA	NaN	NaN	8763.60	14530.33	2369.50	
174	St. Vincent and the Grenadines	VCT	NaN	NaN	7002.80	10632.33	NaN	
175	Sudan	SDN	0.58	2.68	915276.75	1703157.75	574485.20	
176	Suriname	SUR	NaN	NaN	37384.00	51534.83	NaN	
177	Swaziland	SWZ	1.09	5.40	62178.50	92365.60	8480.50	
178	Sweden	SWE	5.04	48.29	319930.80	769249.17	444414.50	
179	Switzerland	CHE	5.78	48.33	278695.60	610657.17	273293.33	
180	Syrian Arab Republic	SYR	1.92	18.09	2063154.25	2571372.00	669369.83	
181	Tajikistan	TJK	6.12	62.27	825375.83	1048672.75	201608.50	
182	Tanzania	TZA	0.57	2.20	1822074.00	1998772.67	136463.00	
183	Thailand	THA	2.26	18.99	2824833.20	5448260.00	2404678.33	
184	Timor-Leste	TLS	NaN	NaN	64309.00	113508.67	18553.00	
185	Togo	TGO	1.86	9.18	399660.00	545861.00	65296.33	
186	Tonga	TON	4.78	49.88	NaN	14847.20	NaN	
187	Trinidad and Tobago	TTO	3.50	50.54	NaN	NaN	NaN	
188	Tunisia	TUN	2.66	16.44	542397.50	1083114.80	346866.67	
189	Turkey	TUR	2.27	20.52	4348902.25	9280750.50	4701843.17	
190	Turkmenistan	TKM	NaN	NaN	417204.00	650998.00	44411.00	
191	Turks and Caicos Islands	TCA	NaN	NaN	1166.00	1912.00	145.50	
192	Tuvalu	TUV	NaN	NaN	848.00	1245.00	NaN	

	Country Name	Country Code	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	s
193	Uganda	UGA	1.21	6.02	NaN	1284008.00	137672.50	
194	Ukraine	UKR	4.87	38.63	2043269.20	2807517.50	2286680.83	
195	United Arab Emirates	ARE	3.53	35.68	227207.40	NaN	128260.33	
196	United Kingdom	GBR	5.53	47.31	2363338.25	5688360.30	2441278.35	
197	United States	USA	5.61	36.19	12442622.00	24170952.40	20273753.00	
198	Uruguay	URY	2.35	18.56	171264.00	304502.33	150660.50	
199	Uzbekistan	UZB	NaN	NaN	2788751.00	4232924.83	267498.33	
200	Vanuatu	VUT	NaN	NaN	14529.00	20412.00	NaN	
201	Venezuela, RB	VEN	2.91	31.94	1562200.40	2426876.50	NaN	
202	Vietnam	VNM	2.94	19.43	4981927.80	NaN	2319984.67	
203	Virgin Islands (U.S.)	VIR	NaN	NaN	NaN	NaN	NaN	
204	West Bank and Gaza	PSE	NaN	NaN	559568.00	709829.33	212711.67	
205	Yemen, Rep.	YEM	1.20	10.68	1019563.50	1661876.25	269814.00	
206	Zambia	ZMB	1.53	16.53	448210.75	NaN	56219.50	
207	Zimbabwe	ZWE	1.95	6.83	461333.50	947097.50	102319.60	

8. Analyse des corrélations et réduction dimensionnelle

L'objectif de cette étape est d'identifier les redondances entre nos 15 indicateurs sélectionnés. Si deux variables sont trop fortement corrélées, elles apportent la même information. Les conserver toutes les deux lors du scoring reviendrait à donner un "double poids" artificiel à une seule et même réalité, ce qui biaiserait notre classement final.

8.1. Méthodologie : Pearson vs Spearman

Pour obtenir une vision complète des relations entre nos variables, nous calculons deux types de coefficients :

1. **Coefficient de Pearson (Corrélation Linéaire)**
   - **Définition** : Il mesure la force d'une relation linéaire entre deux variables (une ligne droite).
   - **Usage** : Idéal pour détecter les indicateurs qui progressent de manière strictement proportionnelle.
   - **Limite** : Il est très sensible aux valeurs aberrantes (outliers), fréquentes dans les données mondiales (ex: disparité entre le PIB de la Chine et celui de l'Estonie).
2. **Coefficient de Spearman (Corrélation Monotone)**
   - **Définition** : Il se base sur le rang des valeurs (le classement) plutôt que sur les valeurs brutes.
   - **Usage** : Plus robuste que Pearson face aux outliers. Il détecte si deux variables évoluent dans le même sens, même si la relation n'est pas une ligne droite parfaite.
   - **Intérêt pour Academy** : Puisque nous comparons des pays aux échelles démographiques et économiques radicalement différentes, Spearman est souvent plus représentatif de la réalité du terrain.

8.2. Stratégie d'arbitrage (Pruning Strategy)

1. **Méthodologie de Fusion** : Le calcul repose sur la logique suivante pour chaque paire d'indicateurs :
   - **Calcul des valeurs absolues** : Nous transformons les coefficients de Pearson (r) et Spearman (ρ) en valeurs absolues pour nous concentrer sur la force de la liaison, quelle que soit sa direction.
   - **Sélection du maximum** : Pour chaque cellule de la matrice, nous conservons la valeur maximale : $max(|r|, |\rho|)$.
   - **Objectif** : Cette approche "conservatrice" permet de détecter une redondance dès qu'elle est soit linéaire, soit monotone, garantissant qu'aucun biais de colinéarité ne subsiste.
2. **Seuil de tolérance** : Tout couple d'indicateurs présentant un coefficient consolidé supérieur à 0.70 est considéré comme redondant. Ce seuil critique déclenche une procédure d'élimination.
3. **Critères de sélection métier** : En cas de conflit (corrélation > 0.70), l'arbitrage est effectué selon les priorités suivantes :
   - **Disponibilité** : Priorité à l'indicateur ayant le meilleur taux de remplissage
   - **Actionnabilité** : Priorité à l'indicateur le plus pertinent pour le modèle d'Academy (ex: favoriser les taux de complétion sur les durées théoriques).
   - **Indépendance** : Priorité à l'indicateur qui présente la corrélation moyenne la plus faible avec l'ensemble des autres variables restantes.
4. **Visualisation** : Nous utilisons une Heatmap unique basée sur cette matrice consolidée. Elle permet d'identifier d'un seul coup d'œil les clusters de variables interdépendantes, simplifiant ainsi la phase finale de nettoyage.

Point de vigilance : Le calcul de corrélation ignore automatiquement les pays ayant des valeurs manquantes (NaN) pour le couple de variables testé. Une gestion rigoureuse de la complétude en amont (Phase 6 & 7) est donc cruciale pour ne pas biaiser les coefficients.

8.3. Arbitrage et sélection finale

Une fois les corrélations identifiées par la heatmap, nous appliquons une règle de décision binaire pour chaque couple de variables dépassant le seuil de 0.70. L'objectif est de transformer une redondance statistique en un choix stratégique.

1. **Critères de suppression** Un indicateur est supprimé s'il remplit l'une des conditions suivantes :
    - **Redondance de volume** : Si deux indicateurs mesurent la même masse démographique (ex: inscrits au collège vs inscrits au lycée), nous supprimons le moins spécifique pour éviter de surestimer le poids de la population.
    - **Redondance de structure** : Si une donnée théorique (ex: durée des études) est trop corrélée à une donnée réelle (ex: taux de réussite), la donnée théorique est écartée car elle n'apporte aucune nuance sur la performance du pays.
    - **Faible variance** : Un indicateur qui présente la même valeur pour la quasi-totalité des pays est supprimé, car il ne permet pas de classer les zones géographiques entre elles.
2. **Critères de conservation** À l'inverse, nous choisissons de conserver un indicateur, même en cas de forte corrélation, s'il est considéré comme un "Pivot Métier" :
    - **Indicateur de faisabilité** : Les variables validant la possibilité technique de l'offre (ex: accès Internet) sont maintenues car elles représentent un risque binaire (Go/No-Go).
    - **Proxy de segmentation** : Nous conservons les indicateurs qui capturent une dimension économique ou comportementale unique (ex: part du privé, accès au supérieur), même s'ils sont statistiquement liés au niveau d'éducation global.

8.1.1. Méthode Pearson :

> **Note Technique : Analyse de Corrélation avec Pandas** L'utilisation de la méthode `.corr()` est le standard en Data Science pour quantifier la relation statistique entre deux variables. Voici le détail de l'implémentation choisie :
>
> 1. Paramètre de la methode `corr()` :
>
> - `methode=`
> - `'pearson'` : Calcule le coefficient de corrélation de Pearson. Il mesure la relation linéaire entre deux variables. Sa valeur varie de -1 à 1.
> - `'spearman'` : Calcule la corrélation de rang de Spearman. Contrairement à Pearson, il est non-paramétrique et mesure la relation monotone (si une

variable augmente, l'autre augmente aussi, même si ce n'est pas de façon linéaire). Il est beaucoup plus robuste face aux valeurs aberrantes

- `numeric_only=True` : Ce paramètre est une bonne pratique de développement. Il force Pandas à ignorer toutes les colonnes non numériques (comme les noms de pays ou codes ISO). Cela évite de lever des erreurs (TypeErrors) et optimise le temps de calcul en ne traitant que les types float64 ou int64

```
corr_pearson = final_academy_dataset.corr(method='pearson', numeric_only=True)
with pd.option_context(
    'display.max_columns', None,
    'display.max_rows', None
):
    display(corr_pearson)
```

	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	Gross enrolment ratio, secondary, both sexes (%)	Gro enrolme rati tertiar bo sexes (%
Barro-Lee: Average years of secondary schooling, age 15+, total	1.000000	0.848682	-0.036077	-0.034034	0.047207	0.764627	0.7225
Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	0.848682	1.000000	-0.033453	-0.028126	0.015990	0.657128	0.6222
Enrolment in lower secondary education, both sexes (number)	-0.036077	-0.033453	1.000000	0.998360	0.929417	-0.000586	-0.0274
Enrolment in secondary education, both sexes (number)	-0.034034	-0.028126	0.998360	1.000000	0.927836	0.007752	-0.0215
Enrolment in tertiary education, all programmes, both sexes (number)	0.047207	0.015990	0.929417	0.927836	1.000000	0.077741	0.1063
Gross enrolment ratio, secondary, both sexes (%)	0.764627	0.657128	-0.000586	0.007752	0.077741	1.000000	0.7905
Gross enrolment ratio,	0.722505	0.622236	-0.027480	-0.021536	0.106310	0.790588	1.0000

	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	Gross enrolment ratio, secondary, both sexes (%)	Gro enrolme rati tertiar bo sexes (%
tertiary, both sexes (%)							
Internet users (per 100 people)	0.733975	0.608832	-0.063629	-0.056045	0.027057	0.808396	0.7473
Literacy rate, population 25-64 years, both sexes (%)	0.663386	0.626033	-0.001303	0.004284	0.067461	0.820809	0.6602
Lower secondary completion rate, both sexes (%)	0.759191	0.676751	0.050218	0.060373	0.121032	0.877298	0.6835
Percentage of enrolment in secondary education in private institutions (%)	-0.157812	-0.153760	0.064235	0.065581	0.011030	-0.107657	-0.1371
Percentage of students in secondary education enrolled in vocational programmes, both sexes (%)	0.335369	0.350584	-0.049587	-0.040804	-0.005881	0.399244	0.4355
School life expectancy, primary and lower secondary, both sexes (years)	0.220380	0.131175	-0.034796	-0.038084	0.020158	0.519086	0.3064
School life expectancy, secondary, both sexes (years)	0.809058	0.735395	-0.009550	-0.000965	0.054558	0.897609	0.7281

	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	Gross enrolment ratio, secondary, both sexes (%)	Gro enrolme rati tertiar bo sexes (%
Theoretical duration of secondary education (years)	0.304145	0.331715	0.029796	0.023719	0.007759	-0.002816	0.1002

8.1.2. Méthode Spearman

```
corr_spearman = final_academy_dataset.corr(method='spearman', numeric_only=True)
with pd.option_context(
    'display.max_columns', None,
    'display.max_rows', None
):
    display(corr_spearman)
```

	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	Gross enrolment ratio, secondary, both sexes (%)	Gro enrolme rati tertiar bo sexes (%
Barro-Lee: Average years of secondary schooling, age 15+, total	1.000000	0.874545	-0.089108	-0.047668	0.242209	0.736545	0.7626
Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	0.874545	1.000000	-0.068011	-0.030387	0.268010	0.650300	0.6937
Enrolment in lower secondary education, both sexes (number)	-0.089108	-0.068011	1.000000	0.992110	0.884723	-0.072461	-0.0102
Enrolment in secondary education, both sexes (number)	-0.047668	-0.030387	0.992110	1.000000	0.916530	-0.016720	0.0481
Enrolment in tertiary education, all programmes, both sexes (number)	0.242209	0.268010	0.884723	0.916530	1.000000	0.242059	0.3971
Gross enrolment ratio, secondary, both sexes (%)	0.736545	0.650300	-0.072461	-0.016720	0.242059	1.000000	0.8280
Gross enrolment ratio,	0.762671	0.693701	-0.010280	0.048100	0.397171	0.828000	1.0000

	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	Gross enrolment ratio, secondary, both sexes (%)	Gro enrolme rati tertiar bo sexes (%
tertiary, both sexes (%)							
Internet users (per 100 people)	0.772191	0.687565	-0.172532	-0.125656	0.142079	0.831415	0.7814
Literacy rate, population 25-64 years, both sexes (%)	0.789637	0.755046	-0.169897	-0.147691	0.154208	0.816114	0.7583
Lower secondary completion rate, both sexes (%)	0.801909	0.716992	-0.235674	-0.174337	0.094395	0.812936	0.7223
Percentage of enrolment in secondary education in private institutions (%)	-0.225458	-0.216679	-0.034062	-0.037439	-0.044430	-0.152742	-0.1712
Percentage of students in secondary education enrolled in vocational programmes, both sexes (%)	0.386619	0.368103	0.066698	0.131125	0.248321	0.473339	0.5260
School life expectancy, primary and lower secondary, both sexes (years)	0.122596	0.057138	-0.136516	-0.133854	0.023878	0.405692	0.2720
School life expectancy, secondary, both sexes (years)	0.792714	0.734847	-0.042705	-0.000363	0.246826	0.855742	0.7504

	Barro-Lee: Average years of secondary schooling, age 15+, total	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in lower secondary education, both sexes (number)	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	Gross enrolment ratio, secondary, both sexes (%)	Gro enrolme rati tertiar bo sexes (%
Theoretical duration of secondary education (years)	0.273660	0.258629	0.107286	0.080843	0.101385	-0.012253	0.0610

8.2.1 Méthodologie de Fusion

> **Note Technique : Matrice de Corrélation Consolidée (Fusion Metrics)** :
>
> Cette cellule implémente une stratégie de sélection de variables conservatrice (Conservative Feature Selection). L'objectif est de s'assurer qu'aucune redondance, qu'elle soit linéaire ou non, n'échappe à l'analyse avant la phase de scoring final.
>
> 1. **Logique de l'Algorithme** : La fonction get_conservative_correlation_matrix repose sur trois piliers techniques :
>
> - **Normalisation par Valeur Absolue (`.abs()`)** : En statistique, une corrélation de -0.90 est aussi forte qu'une corrélation de 0.90 (elles indiquent toutes deux une dépendance totale). Nous transformons les résultats pour ne manipuler que la force de la relation, simplifiant ainsi l'interprétation visuelle.
> - **Maximisation Élémentaire (`np.maximum`)** : Contrairement à une moyenne, le choix du maximum est une approche de "pire scénario". Si Pearson détecte 0.50 mais que Spearman détecte 0.85, la fonction retiendra 0.85. Cela permet de capturer des relations monotones non-linéaires que Pearson sous-estimerait.
> - **Réduction de la Charge Cognitive** : En fusionnant deux matrices de 225 cellules en une seule, nous divisons par deux l'effort d'audit visuel tout en augmentant la fiabilité de la détection.
>
> 2. **Visualisation par Heatmap** :
>
> - **Palette `Reds`** : Contrairement à la palette divergente (bleu-rouge), nous utilisons ici une palette séquentielle (dégradés de rouge). Puisque toutes nos valeurs sont positives (valeurs absolues), l'intensité du rouge indique directement le degré de redondance.
> - Paramètre `fmt=".2f"` : Ce formatage assure une lecture claire des coefficients avec deux décimales, évitant ainsi l'encombrement visuel de la matrice.

```python
def get_conservative_correlation_matrix(df):

    pearson_abs = df.corr(method='pearson', numeric_only=True).abs()
    spearman_abs = df.corr(method='spearman', numeric_only=True).abs()

    combined_corr = np.maximum(pearson_abs, spearman_abs)

    return combined_corr

combined_matrix = get_conservative_correlation_matrix(final_academy_dataset)

plt.figure(figsize=(16, 10))
plt.title("Matrice de Corrélation Consolidée (Max de |Pearson| et |Spearman|)")
sns.heatmap(combined_matrix, annot=True, cmap='Reds', fmt=".2f")
plt.show()
```

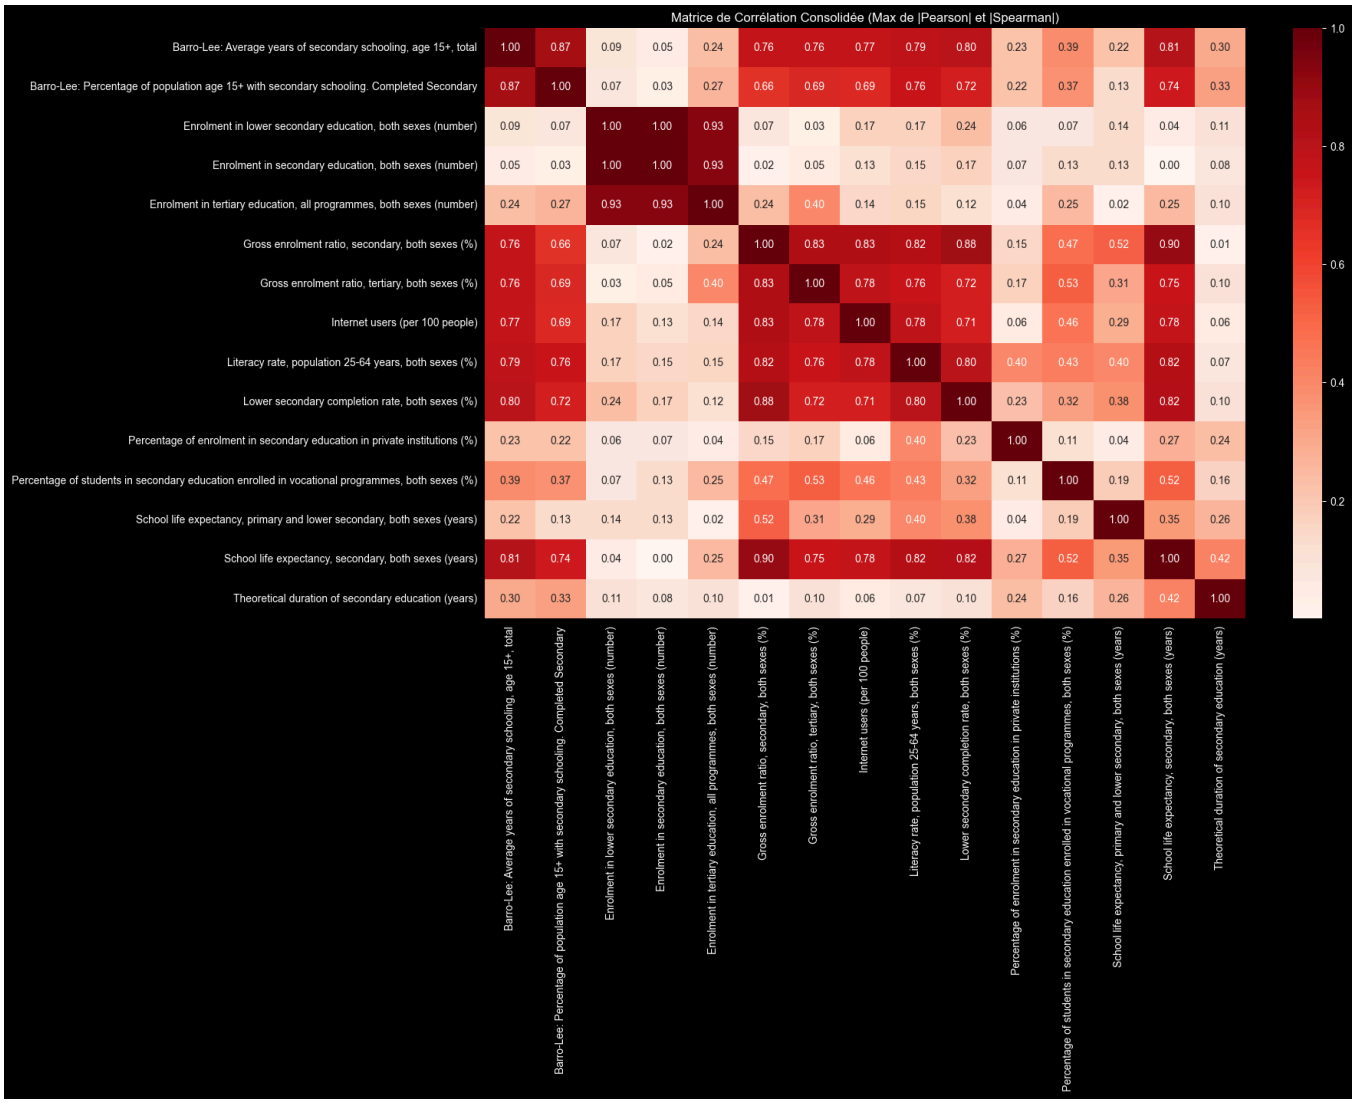

> **Note Technique : Décorateur Visuel Conditionnel**
>
> - **Logic de rendu** : Plutôt que de modifier la fonction heatmap elle-même (qui ne supporte pas nativement les styles par cellule), on utilise l'objet ax (l'axe

Matplotlib) comme un canvas sur lequel on vient dessiner par-dessus.

- **Système de coordonnées** : Dans une Heatmap Seaborn, chaque case d'index (i, j) correspond à une unité de dessin 1x1 sur l'axe. C'est pourquoi on utilise (j, i) pour les coordonnées du rectangle (Matplotlib utilise l'ordre x, y).
- `lw` **(Line Width)** : On règle l'épaisseur à 4 pour que le contour soit bien visible même avec les annotations numériques à l'intérieur.

```
import matplotlib.patches as patches

plt.figure(figsize=(16, 10))
plt.title("Matrice Consolidée avec Alertes de Redondance (|r| > 0.70)")
ax = sns.heatmap(combined_matrix, annot=True, cmap='Reds', fmt=".2f")
for i in range(len(combined_matrix)):
    for j in range(len(combined_matrix.columns)):
        if combined_matrix.iloc[i, j] >= 0.7 and i != j:
            ax.add_patch(patches.Rectangle((j, i), 1, 1, fill=False, edgecolor='blue'

plt.show()
```

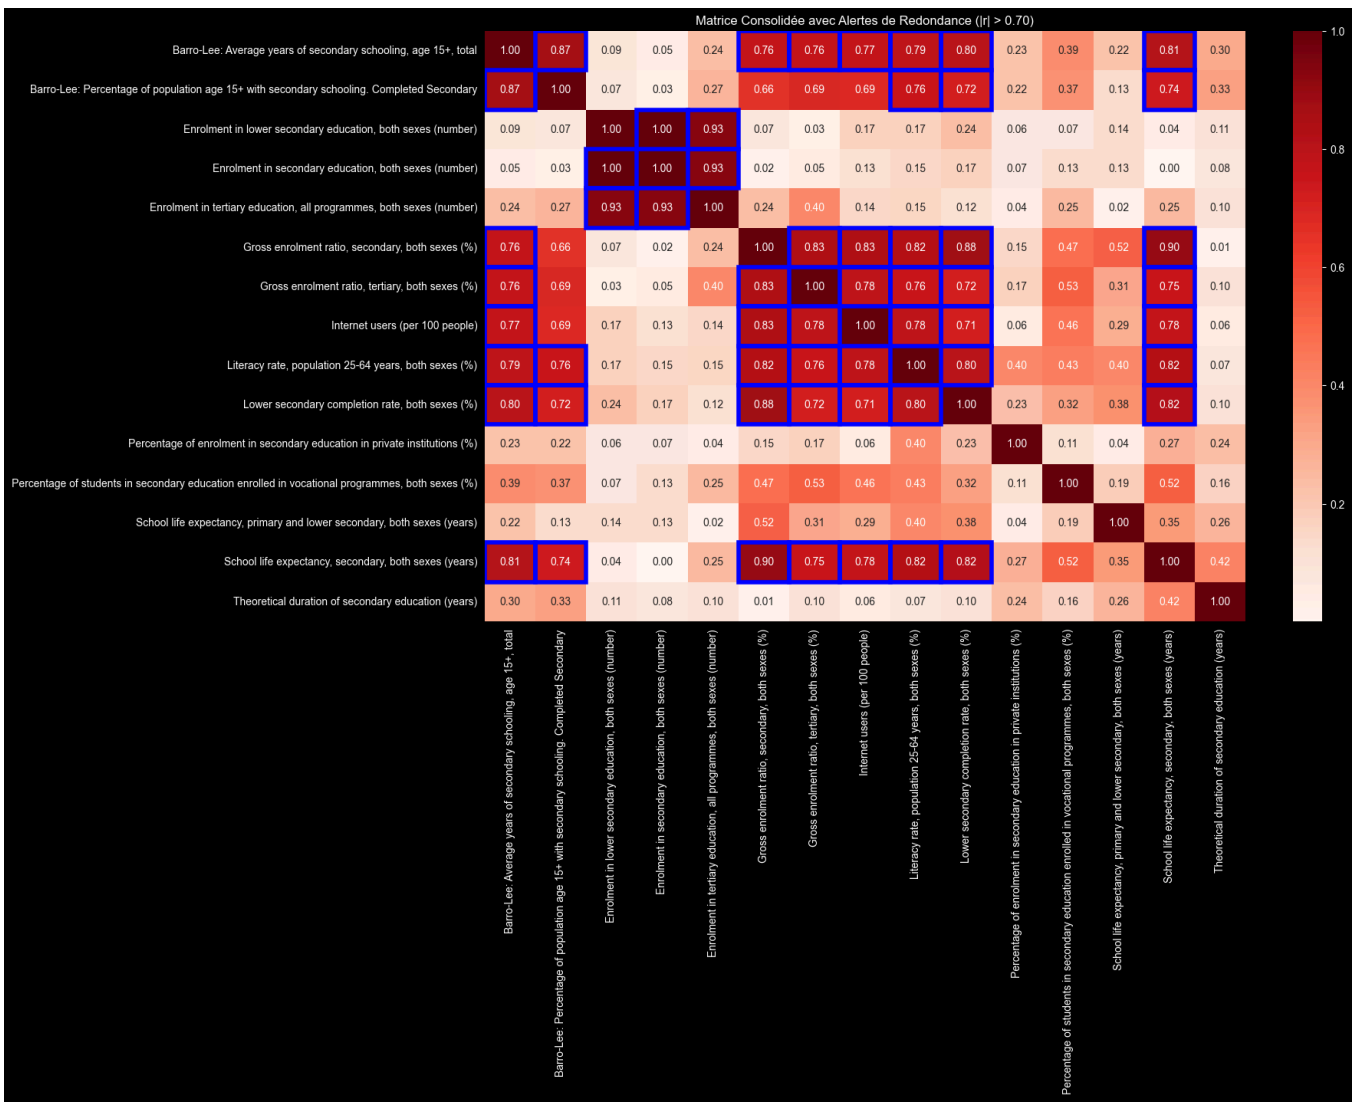

8.3 Arbitrage et sélection finale (Feature Selection)

8.3.1. Indicateurs écartés

Les indicateurs suivants ont été retirés du dataset de calcul :

- **Enrolment in lower secondary / tertiary education** : Fortement corrélés au volume du secondaire. Nous privilégions une seule métrique de volume (secondary education) pour éviter de biaiser le score par la taille démographique globale.
- **Gross enrolment ratio, secondary** : Redondant avec le taux de complétion. Nous privilégions la qualité (réussite) à la simple inscription.
- **School life expectancy (secondary)** : Très corrélé aux taux de scolarisation et de complétion.
- **Barro-Lee (Average years of schooling)** : Bien que pertinent historiquement, cet indicateur est redondant avec les mesures actuelles de diplomation et de complétion.

8.3.2. Justification du maintien des indicateurs à forte corrélation

Certains indicateurs présentent des corrélations élevées ($0.70 < |r| < 0.80$) mais ont été volontairement conservés pour leur valeur métier unique.

- **Internet users (per 100 people)** : Pré-requis technique. Même s'il est corrélé au développement global, il valide la faisabilité de l'offre e-learning. Sans infrastructure, les autres indicateurs n'ont aucune valeur pour Academy.
- **Gross enrolment ratio, tertiary (%)** : Proxy de maturité et de pouvoir d'achat. Il identifie les pays où l'éducation longue est valorisée. C'est un filtre discriminant pour cibler les familles prêtes à investir dans le soutien scolaire pour accéder au supérieur.
- **Lower secondary completion rate (%)** : Indicateur de flux entrant. Il mesure l'efficacité réelle du système. Un taux de complétion élevé garantit un réservoir constant de clients potentiels arrivant au niveau lycée.
- **Literacy rate (25-64 years) (%)** : Dimension sociétale. Bien que corrélé à la scolarisation, il mesure le socle de compétences de la génération des parents (les décideurs d'achat). Sa présence permet d'équilibrer les données "flux d'élèves" avec une donnée "stabilité de l'environnement familial".

```
indicator_to_drop = [
    'Barro-Lee: Average years of secondary schooling, age 15+, total',
    'Enrolment in lower secondary education, both sexes (number)',
    'Enrolment in tertiary education, all programmes, both sexes (number)',
    'Gross enrolment ratio, secondary, both sexes (%)',
    'School life expectancy, secondary, both sexes (years)'
]

final_scoring_dataset = final_academy_dataset.drop(columns=indicator_to_drop)
display(final_scoring_dataset)
```

	Country Name	Country Code	Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed Secondary	Enrolment in secondary education, both sexes (number)	Gross enrolment ratio, tertiary, both sexes (%)	Internet users (per 100 people)	Literacy rate, population 25-64 years, both sexes (%)	L secor compl rate, sexe
0	Afghanistan	AFG	8.65	2.418162e+06	6.209390	5.935758	23.153620	
1	Albania	ALB	42.90	3.425055e+05	56.023516	54.868149	98.764340	94.37
2	Algeria	DZA	17.08	4.594370e+06	33.125055	22.633333	NaN	80.83
3	Andorra	AND	NaN	4.229833e+03	NaN	89.207404	100.000000	
4	Angola	AGO	NaN	8.676580e+05	8.725893	7.316667	62.470200	22.5
...	...	...	...	...	...	...	...	
203	Virgin Islands (U.S.)	VIR	NaN	NaN	NaN	42.929506	NaN	
204	West Bank and Gaza	PSE	NaN	7.098293e+05	46.548922	46.595699	95.705897	77.9
205	Yemen, Rep.	YEM	10.68	1.661876e+06	10.274040	18.556152	NaN	47.27
206	Zambia	ZMB	16.53	NaN	3.993995	15.061367	81.920250	56.71
207	Zimbabwe	ZWE	6.83	9.470975e+05	6.380610	13.567926	85.782445	65.00

208 rows × 12 columns

9. Méthodologie d'Analyse Descriptive et Quantitative

Cette section détaille la démarche analytique utilisée pour évaluer le potentiel de chaque pays. L'objectif est de passer d'une compréhension statistique individuelle de chaque indicateur à une synthèse globale permettant de classer les marchés prioritaires pour Academy.

9.1. Analyse Descriptive des Indicateurs

Conformément aux instructions, nous avons automatisé l'étude de chaque variable pour garantir une analyse homogène et rigoureuse.

1. **Statistiques de centralité et de dispersion** :
   - **La Moyenne (Mean)** : Valeur moyenne mondiale, sensible aux valeurs extrêmes.

- **La Médiane (50%)** : Valeur centrale séparant l'échantillon en deux. La comparaison entre moyenne et médiane nous permet de détecter instantanément l'asymétrie (Skewness) de la distribution.
- **Les Quantiles (25% et 75%)** : Ils définissent les seuils de performance. Le 3ème quartile (75%) est particulièrement crucial car il marque l'entrée dans le "Top 25%" des pays les plus performants pour un critère donné.

2. **Visualisation des Distributions** :
   - **La Densité (KDE)** : Une courbe lissée qui révèle la "forme" mathématique de la distribution (normale, bimodale ou étirée).
   - **La Concentration** : L'identification des zones où se regroupent la majorité des pays.
   - **Les Outliers** : Détection visuelle des pays atypiques qui présentent un potentiel hors norme (ex: géants démographiques).

9.2. Stratégie de Sélection Quantitative

Pour répondre à la demande de Mark et identifier les pays cibles, nous ne nous contentons pas d'un seul critère. Nous proposons une méthode basée sur la Récurrence dans les Tops de Performance.

1. **Le principe de l'algorithme :**
   - **Extraction des Leaders** : Pour chaque indicateur, nous isolons les pays situés dans le haut du classement (Top 15).
   - **Calcul de la Récurrence** : Nous comptabilisons le nombre de fois qu'un pays apparaît dans ces listes d'excellence. Un pays apparaissant dans 8 tops sur 10 est statistiquement plus robuste qu'un pays premier sur un seul critère mais absent des autres.
   - **Filtrage par Faisabilité** : Nous appliquons un filtre strict sur les indicateurs "bloquants" (ex: accès Internet). Un pays ne peut être retenu que s'il dépasse un seuil de connectivité minimale, quel que soit son volume d'élèves.
   - **Avantages de cette méthode :**
     - **Neutralité** : Elle limite l'impact d'un seul indicateur qui pourrait être surévalué.
     - **Stabilité** : Elle favorise les pays présentant un profil équilibré (bonne infrastructure + bon volume + bonne éducation).
     - **Actionnabilité** : Elle fournit une liste finale "clé en main" classée par score de confiance.

9.3. Normalisation des données (Min-Max Scaling)

Pour transformer nos analyses en une recommandation concrète, nous utilisons un algorithme de scoring pondéré. Cette méthode est plus précise qu'un simple classement par indicateur car elle permet de hiérarchiser l'importance de chaque variable selon le business model d'Academy.

1. **Normalisation des données** Nos indicateurs utilisent des unités hétérogènes (millions d'élèves, pourcentages, années). Pour les comparer équitablement, nous appliquons une Normalisation Min-Max.

- **Principe** : Chaque valeur est ramenée sur une échelle de 0 à 1.
- **Résultat** : Le pays le moins performant sur un critère reçoit la note de 0, et le meilleur la note de 1. Cette étape est indispensable pour que les gros volumes (ex: population) n'écrasent pas les ratios (ex: % d'accès Internet).

2. **Attribution des Coefficients** : Nous avons défini des poids stratégiques pour refléter les priorités d'investissement d'Academy

3. **Calcul du Score Final** : Le score final d'un pays est la somme de ses notes normalisées multipliées par leurs coefficients respectifs.

$$Score_{pays} = \sum (ValeurNormalisée_i \times Poids_i)$$

Cette méthode garantit que les pays recommandés présentent le meilleur équilibre entre une infrastructure solide et un volume de clientèle important.

9.1.1. Statistiques de centralité et de dispersion

> **Note technique : Analyse descriptive automatisée** Cette fonction constitue la brique de base du Data Profiling de l'étape 9. Elle permet de passer d'une vision tabulaire à une compréhension statistique de la distribution de chaque indicateur.
>
> 1. Logique Statistique
>
> - `describe()` : Utilise l'implémentation Pandas pour extraire les moments d'ordre 1 (moyenne) et les mesures de dispersion (écart-type, quartiles). Les quartiles Q_1 (25%) et Q_3 (75%) sont essentiels pour identifier les pays "performants" (au-dessus du 75ème percentile).
> - Centralité vs Asymétrie : Le traçage simultané de la Moyenne (Mean) et de la Médiane (50%) permet de détecter visuellement le biais :
> - Si `Mean` > `Median` : Distribution étirée vers la droite (présence d'outliers à fortes valeurs).
> - Si `Mean` ≈ `Median` : Distribution symétrique.
>
> 2. **Implémentation Graphique**
>
> - `sns.histplot` : Choisi pour sa capacité à combiner l'histogramme (fréquences discrètes) et le KDE (Kernel Density Estimate). Le KDE lisse la distribution pour révéler la loi de probabilité sous-jacente.
> - **Gestion des données manquantes** : L'utilisation de .dropna() est critique ici pour éviter les erreurs de calcul du backend de Seaborn lors de la génération de la courbe de densité.
> - `axvline` : L'ajout de lignes verticales (Vertical Axes Lines) transforme un graphique passif en un outil d'aide à la décision, facilitant la lecture des seuils critiques.

3. **Paramétrage de l'affichage**

- `figsize=(12, 5)` : Définit un ratio d'aspect large, optimal pour observer l'étalement des données sur l'axe X, particulièrement pour les indicateurs avec une "longue traîne" comme les volumes d'inscriptions.
- `plt.show()` : Force le vidage du buffer graphique à chaque appel, garantissant que chaque indicateur dispose de son propre espace de rendu sans superposition.

```
def analyze_and_plot_indicator(df, indicator_name):
    stats = df[indicator_name].describe()
    display(stats.to_frame().T)
    plt.figure(figsize=(12, 5))
    sns.histplot(df[indicator_name].dropna(), kde=True, color="teal")
    plt.axvline(stats['mean'], color='red', linestyle='--', label=f"Moyenne: {stats['r
    plt.axvline(stats['50%'], color='orange', linestyle='-', label=f"Médiane (Q2): {st

    plt.title(f"Distribution et Dispersion : {indicator_name}")
    plt.legend()
    plt.show()
```

Note Technique : Guide d'interprétation des Distributions (KDE & Histogrammes)
Cette note détaille la méthodologie de lecture des graphiques générés par la fonction `analyze_and_plot_indicator`. L'objectif est de traduire des formes géométriques en opportunités business pour Academy.

1. **Analyse de la Forme**

- **Asymétrie à droite** : La "bosse" est à gauche, avec une longue traîne vers les valeurs élevées.
  - Signification : La majorité des pays ont des scores faibles. Les pays dans la traîne sont des outliers à haut potentiel (ex: volumes d'étudiants massifs).
- **Asymétrie à gauche** : La "bosse" est à droite.
  - Signification : La majorité des pays ont déjà atteint des scores élevés. C'est le signe d'un marché mature ou d'un pré-requis largement rempli (ex: Taux d'alphabétisation).
- **Distribution Bimodale** : Présence de deux sommets.
  - Signification : Le monde est divisé en deux groupes distincts (ex: pays développés vs pays en développement), sans véritable "milieu".

2. **Lecture des Indicateurs de Centralité**

- **Ligne Orange (Médiane / Q2)** : C'est le point de bascule. 50% des pays sont à gauche, 50% à droite. Elle est plus robuste que la moyenne face aux valeurs extrêmes.
- **Ligne Rouge (Moyenne)** : Si elle est très éloignée de la médiane, cela confirme que quelques pays "poids lourds" tirent les statistiques mondiales vers le haut ou

vers le bas.

3. **Utilisation des Quartiles pour le Ciblage**

- **[Min -> Q1] (0-25%)** : Zone de risque. Pays présentant un retard structurel sur l'indicateur.
- **[Q1 -> Q3] (25-75%)** : Le "ventre mou" du marché mondial. C'est la zone de référence.
- **[> Q3] (Top 25%)** : Zone de performance. Ce sont les pays qui surperforment par rapport à la norme mondiale. Pour Academy, nous chercherons les pays qui se situent systématiquement dans ce dernier quart du graphique pour un maximum d'indicateurs.

9.1.2. Visualisation des Distributions pour chaque indicateur

```
numeric_columns = final_scoring_dataset.select_dtypes(include=['number']).columns
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[0])
```

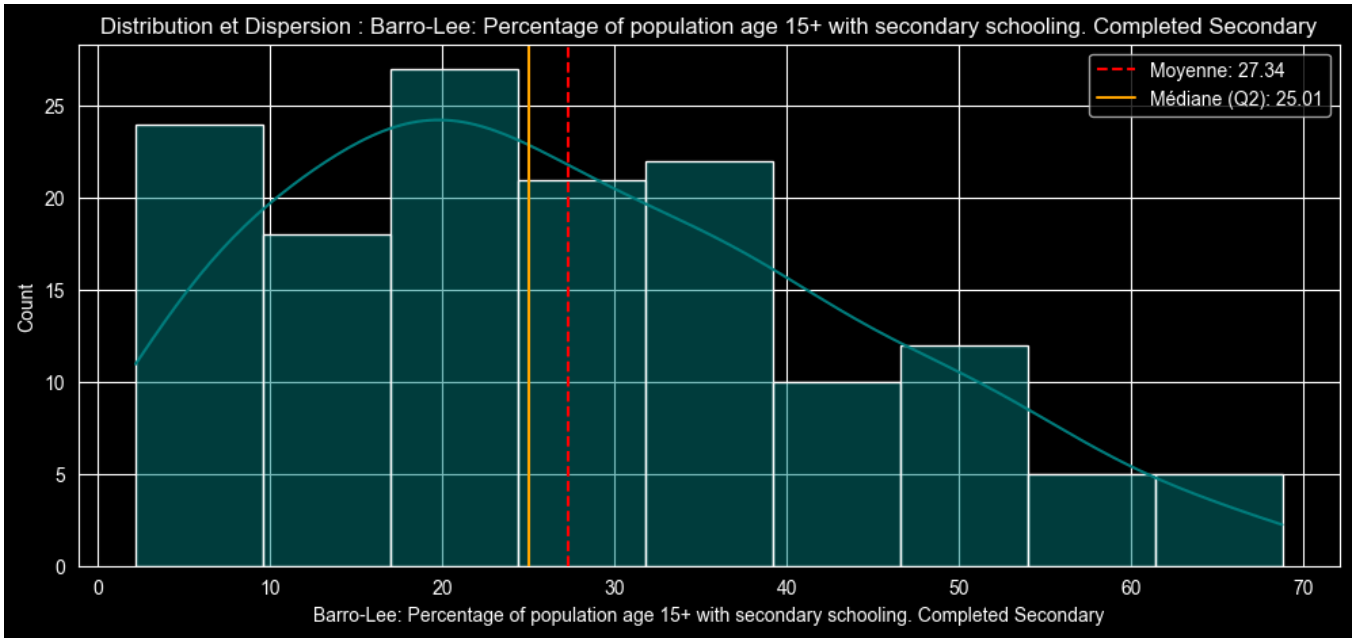

Barro-Lee : Completed secondary

- **Forme** : Distribution étalée avec une légère asymétrie à droite.
- **Analyse** : La médiane se situe autour de 25%. Cela signifie que dans la moitié des pays, seulement un quart de la population a terminé le secondaire.
- **Potentiel** : Les pays situés dans le dernier quartile (au-dessus de 40-50%) représentent des marchés matures où l'éducation est déjà bien ancrée.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[1])
```

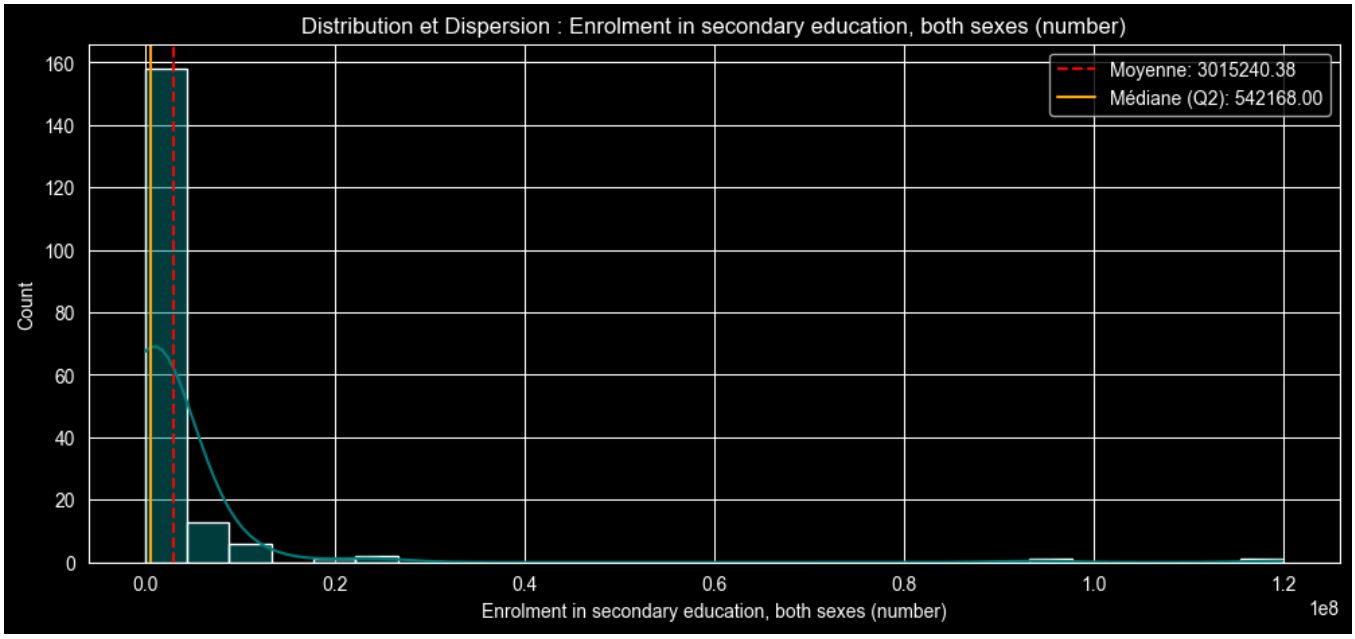

> **Enrolment in secondacry education (number)**
>
> - **Forme** : Distribution extrêmement asymétrique à droite ("Long Tail").
> - **Analyse** : La quasi-totalité des pays sont massés près de zéro, avec quelques géants (outliers) comme l'Inde ou la Chine qui tirent la moyenne vers le haut.
> - **Potentiel** : Cet indicateur de volume pur isolera les très grands marchés mondiaux.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[2])
```

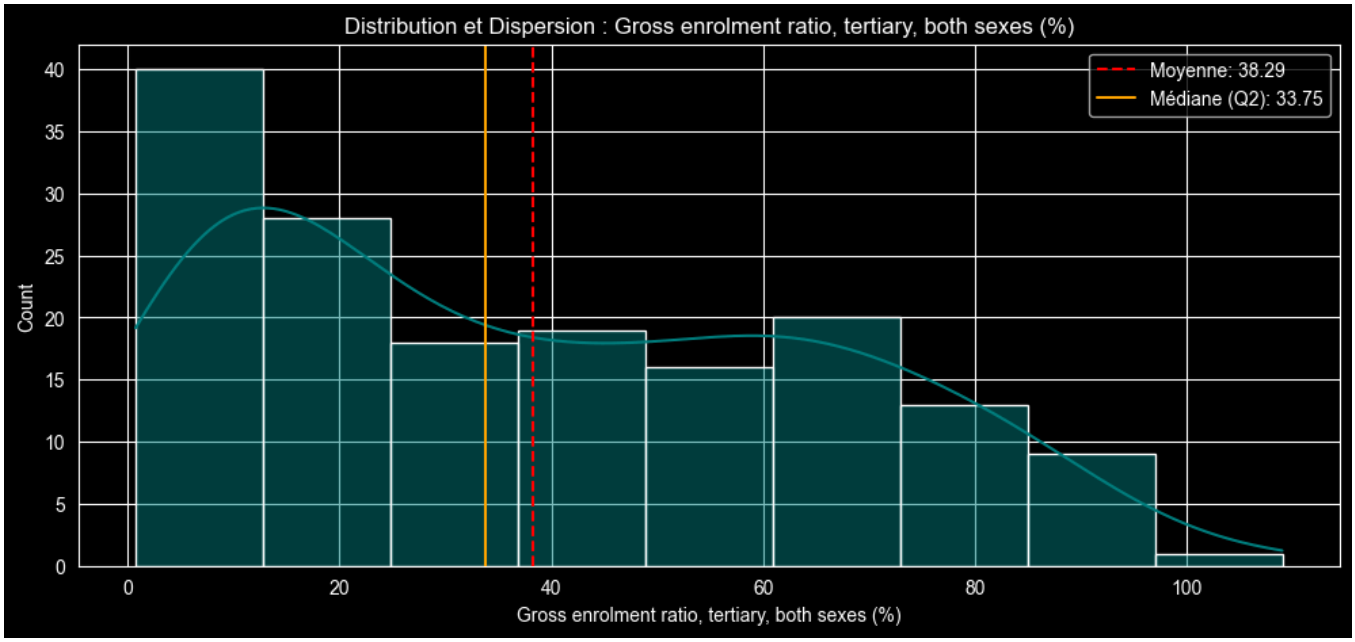

> **Gross enrolment ratio, tertiary, both sexes (%)**
>
> - **Forme** : Distribution bimodale (deux bosses) ou très étalée.

> - **Analyse** : Il y a une séparation nette entre les pays à faible accès au supérieur (0-20%) et ceux à fort accès (60%+).
> - **Potentiel** : C'est un excellent filtre pour identifier les pays avec une classe moyenne montante prête à investir dans les études longues.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[3])
```

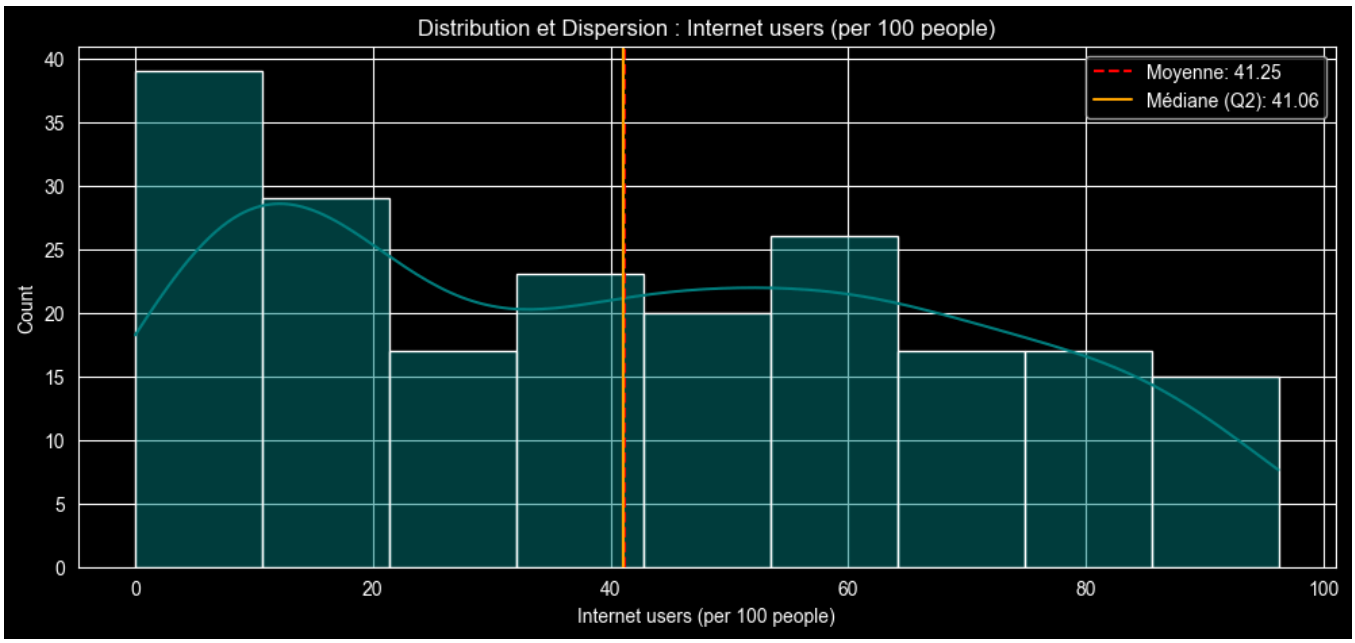

> **Internet users (per 100 people)**
>
> - **Forme** : Distribution quasi-uniforme avec une bosse vers le bas.
> - **Analyse** : La médiane et la moyenne sont très proches (~41%).
> - **Potentiel** : C'est l'indicateur de faisabilité technique. Les pays à droite de la médiane (plus de 41%) sont les cibles prioritaires pour une offre e-learning.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[4])
```

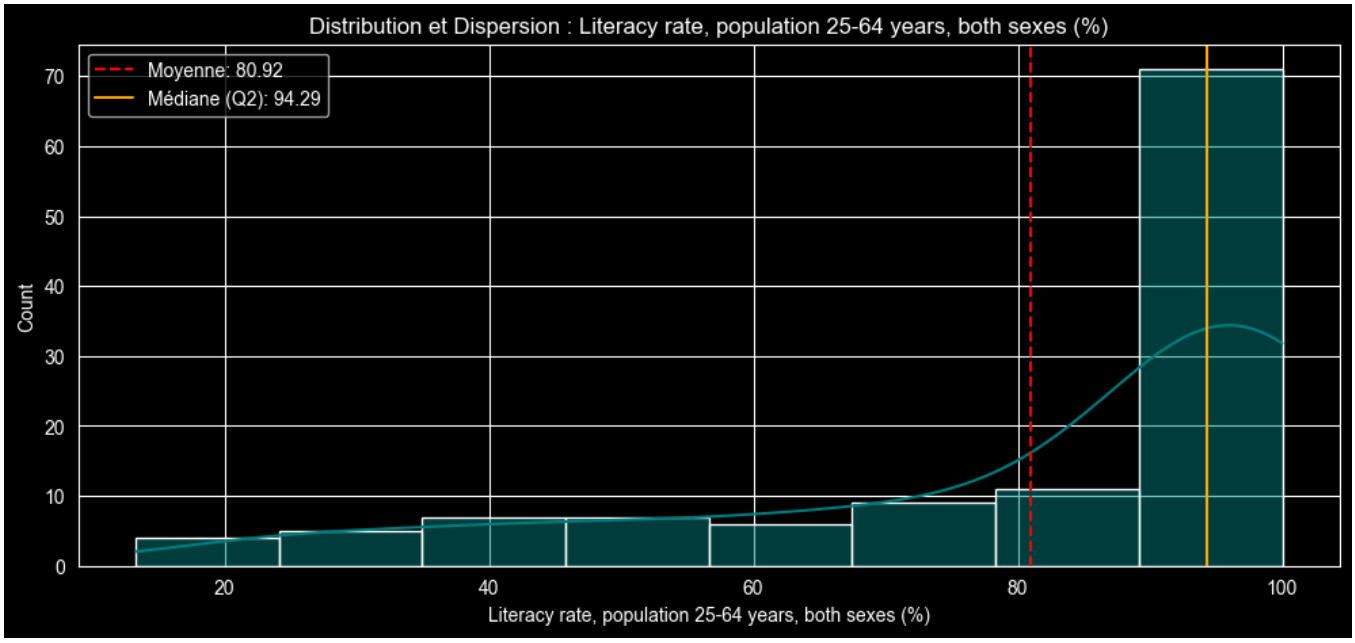

> **Literacy rate, population 25-64 years, both sexes (%)**
>
> - **Forme** : Forte asymétrie à gauche.
> - **Analyse** : La majorité des pays ont un taux très élevé (Médiane à **94%**).
> - **Potentiel** : Cet indicateur est rassurant : la base de clients (parents décideurs) est massivement alphabétisée dans la plupart des pays cibles.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[5])
```

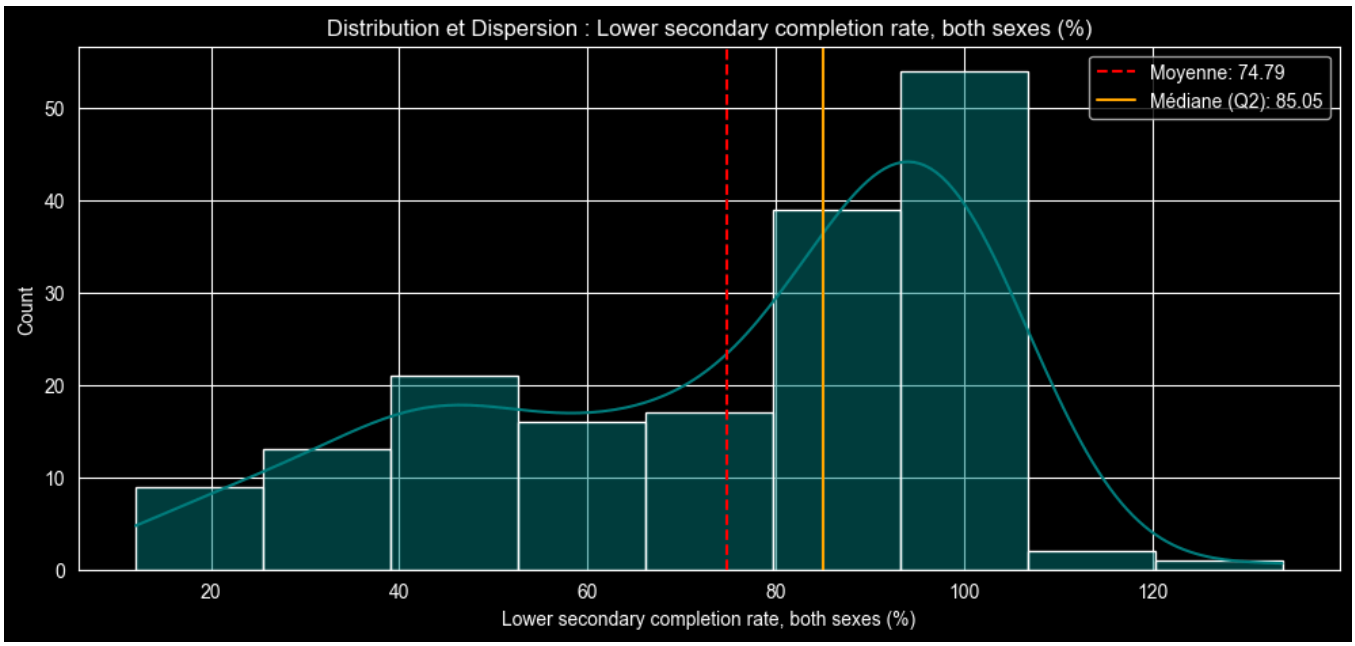

> **Lower secondary completion rate, both sexes (%)**
>
> - **Forme** : Distribution asymétrique à gauche.
> - **Analyse** : La bosse principale se situe entre 80% et 100%.

> - **Potentiel** : Cela confirme un flux constant d'élèves terminant le collège et prêts à entrer dans le cycle secondaire (le cœur de cible d'Academy).

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[6])
```

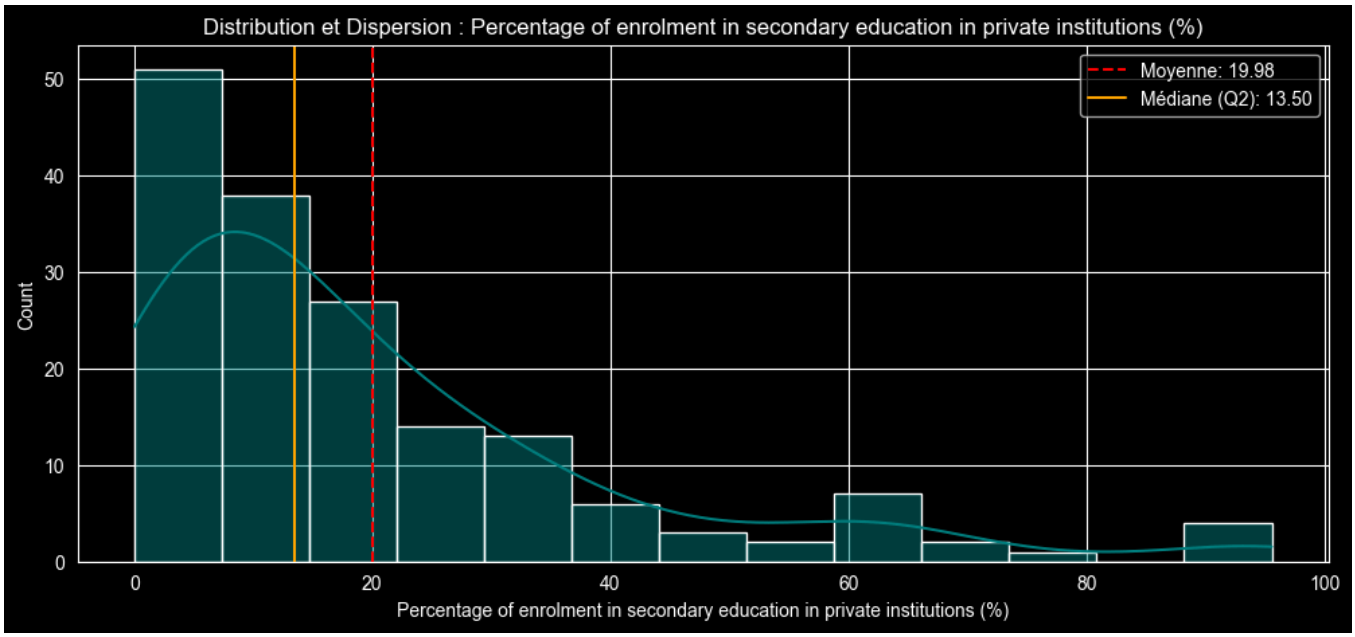

> **Percentage of enrolment in secondary education in private institutions (%)**
>
> - **Forme** : Décroissance exponentielle (étirée à droite).
> - **Analyse** : Dans la majorité des pays, le privé représente moins de **13.5%** (médiane).
> - **Potentiel** : Les pays dans la queue de distribution (à droite) sont des "Niches" à fort potentiel où l'éducation payante est déjà une norme culturelle.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[7])
```

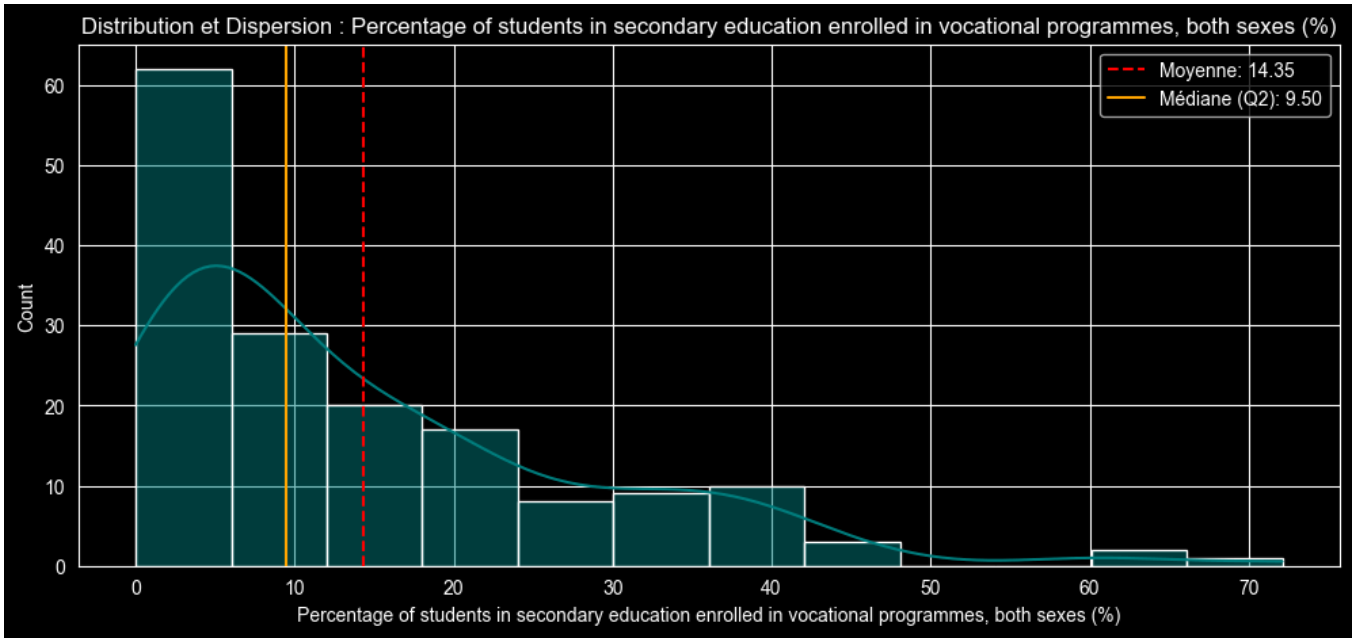

> **Percentage of students in secondary education enrolled in vocational programmes, both sexes (%)**
>
> - **Forme** : Asymétrie à droite très marquée.
> - **Analyse** : La plupart des pays ont moins de 10% d'élèves en filière professionnelle.
> - **Potentiel** : Plus ce taux est bas, plus le pays privilégie la filière académique générale, ce qui correspond exactement au catalogue d'Academy.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[8])
```

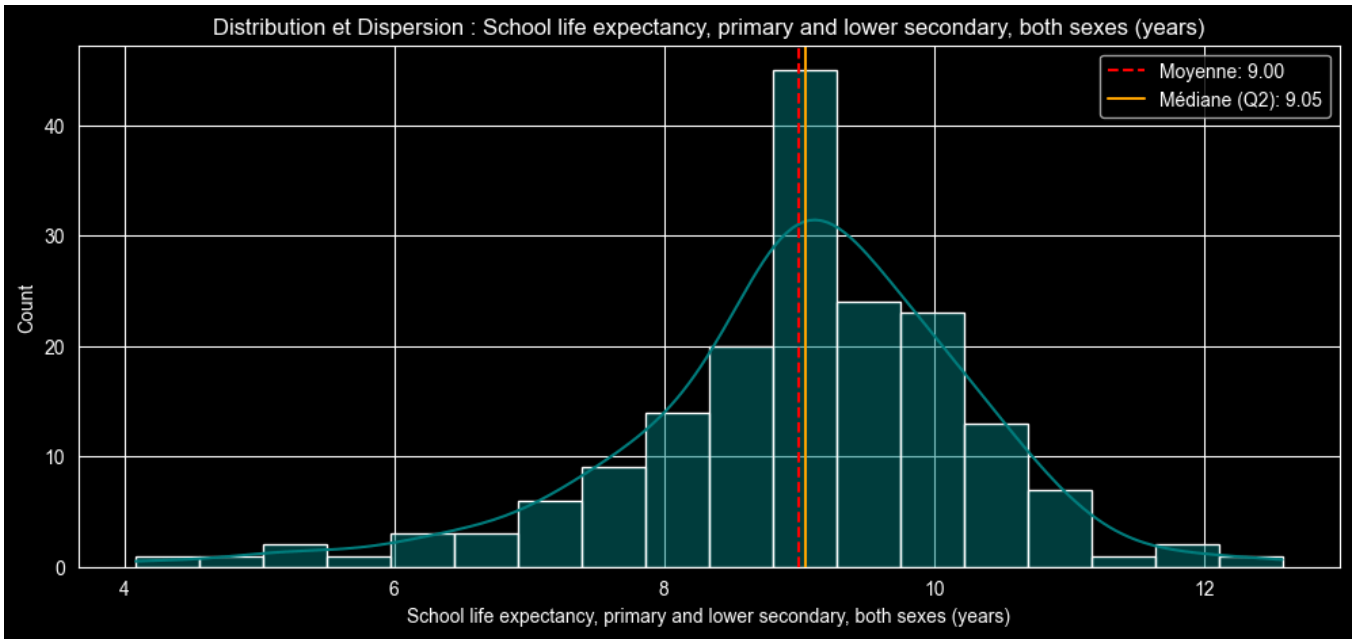

> **School life expectancy, primary and lower secondary, both sexes (years)**

- **Forme** : Distribution "Normale" (en cloche).
- **Analyse** : Très équilibrée autour de **9 ans**.
- **Potentiel** : Cet indicateur est stable. Les pays au-dessus de 10 ans offrent un environnement éducatif plus durable et profond.

```
analyze_and_plot_indicator(final_scoring_dataset, numeric_columns[9])
```

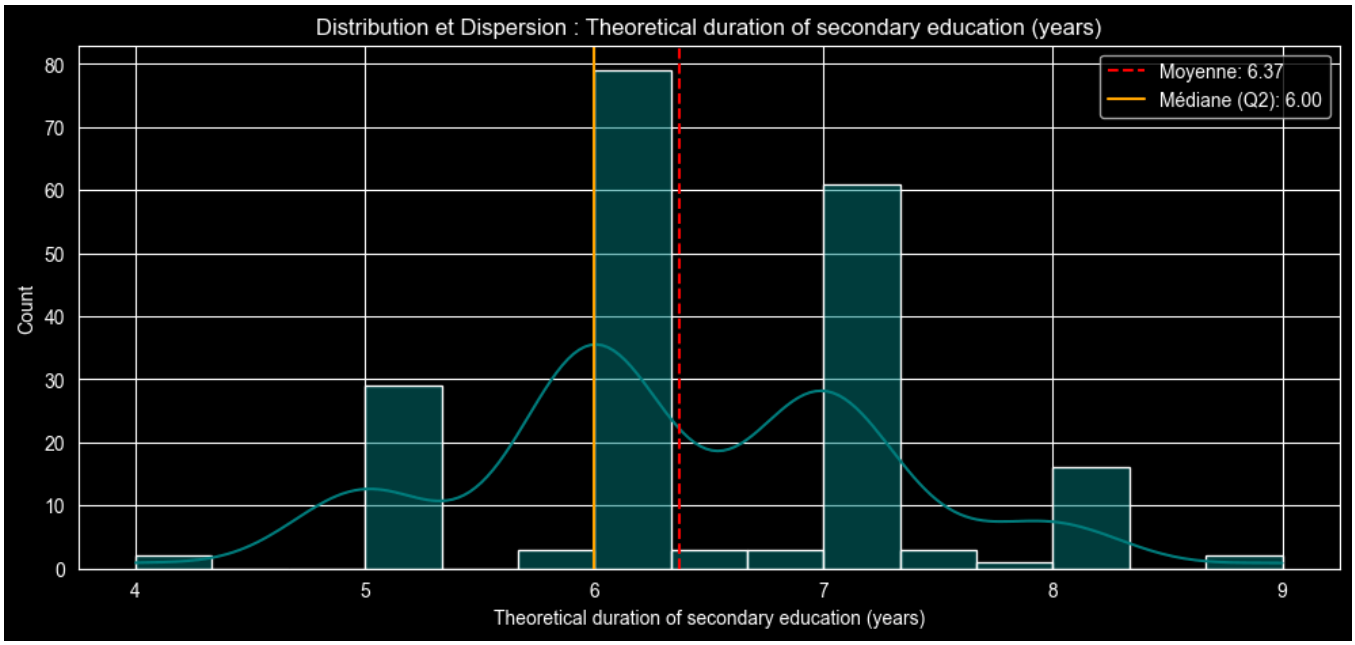

Theoretical duration of secondary education (years)

- **Forme** : Distribution discrète (en bâtons).
- **Analyse** : La norme mondiale est de **6 ans** (Médiane).
- **Potentiel** : Peu discriminant pour le classement, mais crucial pour calibrer la durée des abonnements et les programmes par pays.

9.2. Stratégie de Sélection Quantitative

Note Technique : Algorithme de Recommandation par Récurrence

Cette fonction constitue le moteur de décision final pour répondre à la problématique d'Academy. Elle transforme les performances individuelles par indicateur en un score de fiabilité globale.

1. **Logique Algorithmique**

- **Isolement des élites** : Pour chaque dimension (colonne numérique), la fonction effectue un tri descendant (sort_values) et extrait les n meilleurs pays ($n = 15$ par défaut).

- **Comptage des occurrences** : Un dictionnaire de fréquences (occurrence_count) incrémente le score d'un pays chaque fois qu'il apparaît dans un "Top 15".
- **Agrégation** : Le score final représente le nombre de critères pour lesquels le pays est considéré comme un leader mondial.

2. **Détails de l'implémentation**

- **Sélectivité dynamique** : Utilisation de `select_dtypes(include=['number'])` pour ignorer automatiquement les métadonnées (`Country Name` , `Code`) et ne traiter que les variables de scoring.
- **Structure de données** : Le passage par un dictionnaire pour le comptage assure une complexité temporelle de $O(n \times m)$ (où n est le nombre de colonnes et m la taille du Top), ce qui est très performant sur des datasets de cette taille.
- Sortie : La conversion finale en `DataFrame` permet une exploitation immédiate (export CSV, visualisation ou filtrage complémentaire).

```
def get_top_countries_recommendation(df, top_n=15):
    occurrence_count = {}
    numeric_cols = df.select_dtypes(include=['number']).columns

    for col in numeric_cols:
        top_list = df.sort_values(by=col, ascending=False).head(top_n)['Country Name']

        for country in top_list:
            occurrence_count[country] = occurrence_count.get(country, 0) + 1
    recommendation_df = pd.DataFrame(
        list(occurrence_count.items()),
        columns=['Country Name', 'Score_Recurrence']
    ).sort_values(by='Score_Recurrence', ascending=False)

    return recommendation_df

final_recommendation = get_top_countries_recommendation(final_scoring_dataset)
display(final_recommendation.head(15))
```

	Country Name	Score_Recurrence
0	Czech Republic	3
7	Slovenia	3
13	Lithuania	3
37	Ukraine	3
54	Uzbekistan	3
74	Curacao	3
8	Germany	3
61	Croatia	3
31	Finland	3
35	Spain	2
47	Netherlands	2
36	Australia	2
84	Suriname	2
32	Grenada	2
39	Iceland	2

9.3.2. Attribution des coefficients

> **Note Technique : Justification des Coefficients de Pondération**
>
> 1. Les multiplicateurs critiques ($w \geq 2.5$)
>
> - Internet users : Sans connectivité, le business model s'effondre. C'est l'indicateur "pivot".
> - Enrolment (Secondary) : C'est l'indicateur de volume pur. Un pays avec un excellent taux de pénétration mais seulement 10 000 élèves au total sera moins rentable qu'un marché de masse.
>
> 2. Les leviers de conversion ($w \in [1.0, 2.0]$)
>
> - Tertiary & Barro-Lee : Ces indicateurs mesurent l'appétence des familles pour les études longues. Plus le taux d'accès au supérieur est élevé, plus le besoin de soutien scolaire pour y parvenir est fort.
> - Private institutions & Literacy : Ils valident la solvabilité et le niveau d'éducation des parents (décideurs d'achat).
>
> 3. Les variables de contexte ($w = 0.5$)

> - Vocational / Duration : Bien qu'utiles pour la logistique des cours, ces variables n'indiquent pas directement le potentiel de chiffre d'affaires. Un poids faible évite qu'elles ne parasitent le classement final.

```
weights = {
    # PRIORITÉ 1 : Infrastructure & Faisabilité (Indispensable pour l'e-learning)
    'Internet users (per 100 people)': 3.0,

    # PRIORITÉ 2 : Volume du marché cible (Taille du réservoir de clients)
    'Enrolment in secondary education, both sexes (number)': 2.5,

    # PRIORITÉ 3 : Potentiel de croissance & CSP+ (Capacité à investir dans le supérie
    'Gross enrolment ratio, tertiary, both sexes (%)': 2.0,
    'Barro-Lee: Percentage of population age 15+ with secondary schooling. Completed S

    # PRIORITÉ 4 : Qualité & Écosystème (Fiabilité du flux d'élèves)
    'Lower secondary completion rate, both sexes (%)': 1.0,
    'Literacy rate, population 25-64 years, both sexes (%)': 1.0,
    'Percentage of enrolment in secondary education in private institutions (%)': 1.0,

    # PRIORITÉ 5 : Indicateurs de structure (Contexte moins impactant sur le CA)
    'School life expectancy, primary and lower secondary, both sexes (years)': 0.5,
    'Percentage of students in secondary education enrolled in vocational programmes,
    'Theoretical duration of secondary education (years)': 0.5
}
```

9.3.3. Calcul du score final

> **Note Technique : Optimisation et Intégration**
>
> Algorithme de Scoring Pondéré : Pour classer les pays, nous utilisons un modèle d'agrégation linéaire basé sur des poids métier. Cette approche permet de hiérarchiser les critères selon les priorités stratégiques d'Academy. **Etape de calcul** :
>
> - **Normalisation Min-Max** : Aligne tous les indicateurs sur une échelle de $[0, 1]$ pour neutraliser les différences d'unités (pourcentages vs millions d'habitants).
> - **Application des coefficients** : Multiplication de chaque valeur normalisée par son poids d'importance stratégique (ex: Internet x3).
> - **Calcul du Score Final** : Somme pondérée de l'ensemble des indicateurs pour obtenir une note globale d'attractivité.

```
from sklearn.preprocessing import MinMaxScaler

def calculate_final_score(df, weights):
    numeric_cols = list(weights.keys())
    scaler = MinMaxScaler()
    df_norm = df.copy()
    df_norm[numeric_cols] = scaler.fit_transform(df[numeric_cols])

    df['Final_Score'] = sum(df_norm[col] * weights[col] for col in numeric_cols)
```

```
    return df.sort_values(by='Final_Score', ascending=False)
```

```
top_countries = calculate_final_score(final_scoring_dataset, weights)
display(top_countries[['Country Name', 'Final_Score']].head(15))
```

	Country Name	Final_Score
59	Estonia	7.229593
108	Lithuania	7.166920
37	Chile	6.927987
170	Spain	6.896788
102	Latvia	6.882485
45	Croatia	6.856189
38	China	6.804484
71	Greece	6.734068
94	Kazakhstan	6.601781
90	Italy	6.455695
152	Russian Federation	6.378852
159	Serbia	6.267359
151	Romania	6.158112
84	India	6.147839
1	Albania	6.030360

Top 5 Final Recommandé

Pour sortir ce Top 5, nous cherchons les pays qui font l'unanimité dans les deux listes. C'est la méthode la plus sûre pour un investissement :

1. **Lituanie** : C'est la grande gagnante. 2ème au score pondéré (7.16) et 2ème en récurrence (4). Elle est technologique, éduquée et stable.
2. **Estonie** : Numéro 1 incontestée au score pondéré (7.22). Même si elle apparaît un peu plus bas en récurrence, son avance sur Internet et la qualité de son système éducatif en font la cible prioritaire n°1 pour de l'e-learning.
3. **Croatie** : Championne de la récurrence (4) et très bien classée au score (6.85). C'est le pays le plus "équilibré" de l'étude.
4. **Chili** : Premier pays non-européen à s'imposer. Il est 3ème au score pondéré (6.92) et présent dans le top récurrence (3). C'est la porte d'entrée idéale pour le marché sud-américain.

5. **Espagne** : L'Espagne est un choix stratégique fort (4ème au score, présent en récurrence) car elle offre un volume d'élèves bien plus important que les pays baltes, tout en ayant des infrastructures solides.